中国科学院大学
University of Chinese Academy of Sciences

文件系统基础

中国科学院大学计算机与控制学院
中国科学院计算技术研究所

2019-12-16

内容提要

- FS基础
  - 用户视图
  - 基本概念
- FS内部结构

为什么需要文件系统（File System, FS）

- 持久化保存数据需求（persistence)
  - 进程结束、关机/关电、宕机/掉电
  - 持久化存储设备：磁盘、SSD等
- FS是对持久化数据存储的抽象
  - 给用户/程序开发者提供一个逻辑上的持久化存储
    - 简单、易理解、操作方便
  - 将复杂的、公共的管理功能从用户程序中移出
    - 存储设备管理（例如磁盘）
    - 程序持久化数据的组织和增删改查
- 对FS的基本需求
  - 能够保存大量（复杂多样）的信息 → 管理问题
  - 多个进程同时访问 → 并发控制问题
  - 多用户共享数据 & 私有数据 → 安全保护问题

文件系统的用户视图

- 文件：数据组织的单位
  - 文件是命名的字节数组
  - 用户将数据组织成文件，根据文件名来访问对应的数据
  - FS不感知文件的内容：使用文件的进程负责解析内容
- 目录：文件组织的单位
  - 一组文件和目录的命名集合
  - 父目录、子目录
  - 无重名
- 名字空间：树形层次结构
  - 文件系统的逻辑视图

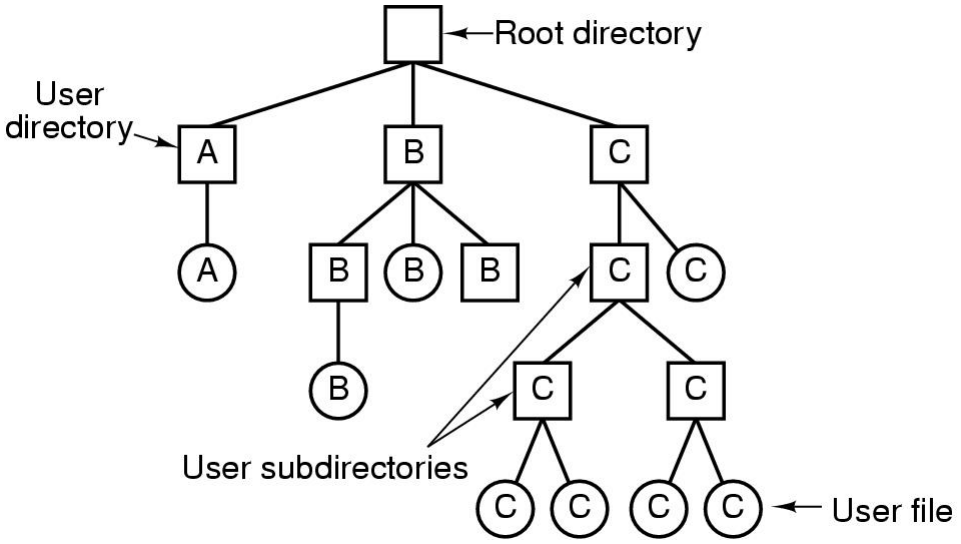

文件

- 文件名：由字母、数字及某些特殊字符组成的字符串
  - 用户根据文件名来访问文件
  - 文件扩展名：描述文件的用途
- 文件属性
  - 文件大小、所有者、时间戳、访问权限
  - 文件逻辑地址：0 .. fsize-1，指示数据在文件中的位置
- 文件内容：无结构
  - OS将文件视为无结构的字符数组
  - 程序开发者可以定义任意结构的文件
- 文件的类型
  - 常规文件、目录文件、设备文件、可执行文件

文件

- 文件的访问
  - 打开文件 & 文件描述符
  - 当前位置：文件逻辑地址，[0, fsize-1]（每个文件）
  - 访问方式（Access mode）：读、写、执行

文件访问接口（syscall）

- 创建文件：fd = creat(fname, mode);
- 删除文件：unlink(fname);
- 打开文件：fd = open(fname, flags, mode);
- 关闭文件：close(fd);
- 读文件：　rn = read(fd, buf, count);
- 写文件：　wn = write(fd, buf, count);
  - 追加写：用O_APPEND打开文件
- 定位文件：lseek(fd, offset, whence);
- 写回文件：fsync(fd);
- 截断文件：truncate(fname, length);
- 获取属性：stat(fname, attbuf); 或 fstat(fd, attbuf);
- 重命名文件 rename(oldpath, newpath);

文件访问模式（Access pattern）

- 顺序访问
  - 从头到尾依次访问每个文件块
  - 例子：观看一部电影，读一篇文章
  - 顺序访问文件 ≠ 磁盘上顺序访问扇区
- 随机访问
  - 每次随机访问一个文件块
  - 例子：只看电影的某些片段
- 按关键字访问
  - 查找包含关键字的文件及段落
  - FS没有提供此功能
  - 例子：数据库查找和索引

目录

- 路径
  - 根目录 & 当前工作目录
  - .：当前目录
  - ..：父目录
  - 绝对路径 vs. 相对路径

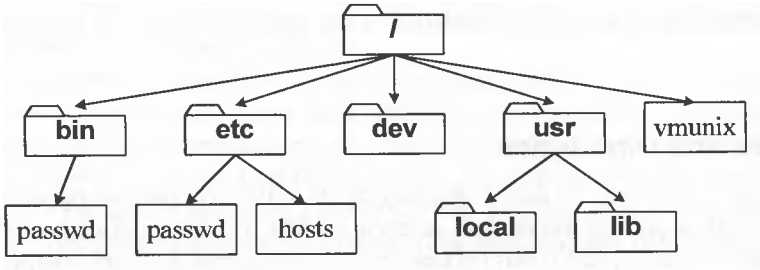

- 目录：一种特殊的文件
  - 名字 & 属性
  - 目录和文件用相同的数据结构：inode
    - 用一个标志（i_mode）来区分文件与目录
  - 目录内容：描述它所包含的目录和文件集合
    - 有结构：逻辑上是一张表
    - 目录项：每个成员一项
    - 不同FS采用不同的结构
    - 由FS负责维护和解析目录内容
    - 访问目录 vs 访问文件： 不同的syscall

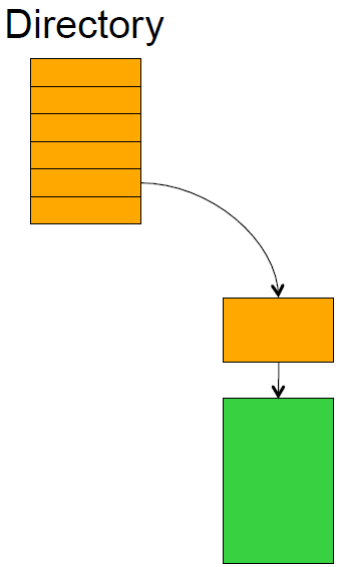

目录访问接口（syscall）

- 创建目录　　mkdir(dirname, mode);
- 删除目录　　rmdir(dirname);
- 打开目录　　fd=open(dirname, flags);
- 关闭目录　　close(fd);
- 读目录　　readdir(fd, direntbuf, count);

硬链接 link

- 为文件共享提供的一种手段
  - link 系统调用 或 ln命令
  - ln source link_name
  - 为文件创建一个新名字，无数据拷贝
  - 多个名字指向同一个文件
  - 一个文件可以同时有多个名字，甚至位于多个目录中

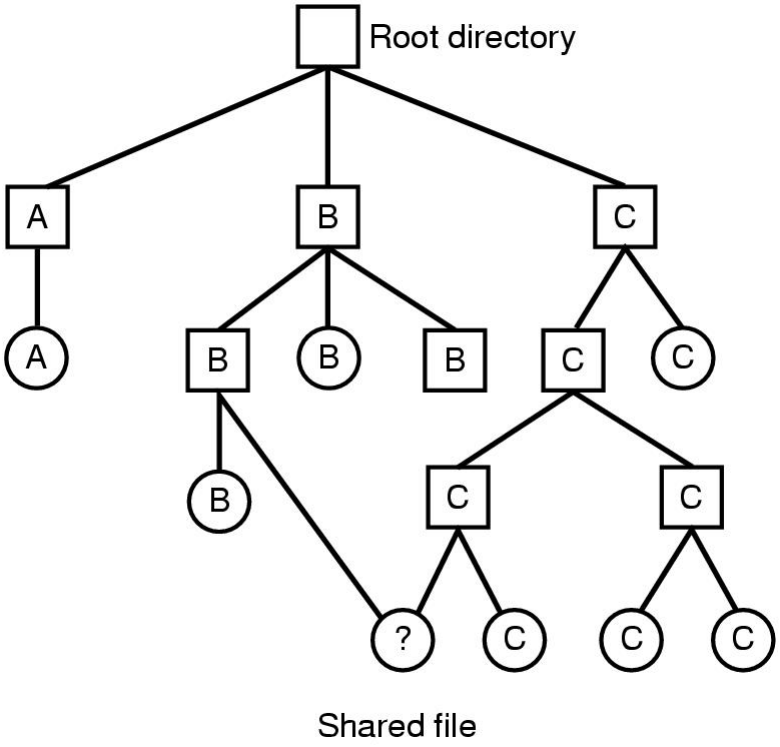

Shared file

符号链接

- 硬链接的限制
  - 不允许对目录做 link
  - 不能跨FS做link
- 另一种文件共享的手段
  - symlink系统调用 或 ln –s 命令
  - ln –s source link_name
  - 创建一个普通文件link_name，该文件内容为source的绝对路径

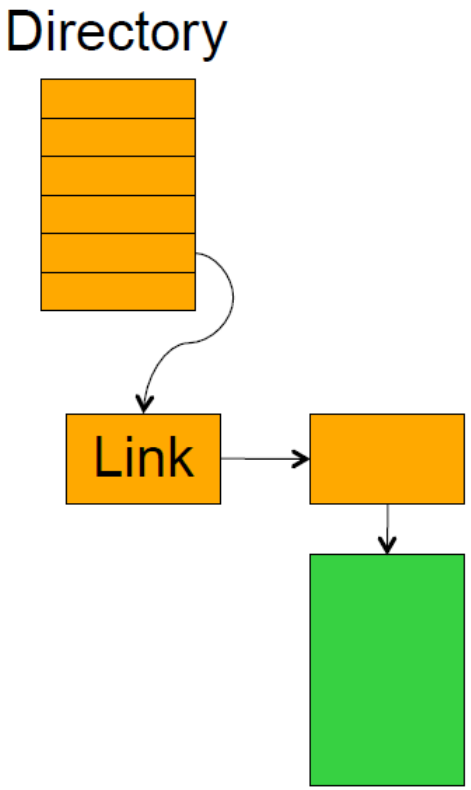

符号链接与硬链接有什么区别？

链接操作接口（syscall）

- 硬链接　　link(oldpath, newpath);
- 符号链接　　symlink(srcpath, linkpath);

内容提要

- FS基础
- FS内部结构
  - 虚拟文件系统与物理文件系统
  - 主要数据结构
  - 磁盘布局与超级块

虚拟文件系统（VFS）

- 同时挂载不同类型的FS
  - SUNFS访问本地的磁盘
  - SUN NFS访问远端服务器的FS

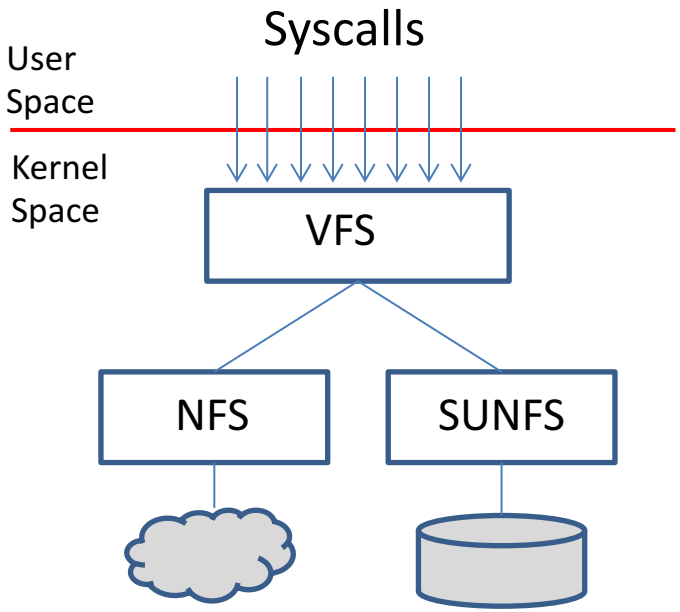

S.R. Kleiman, **Vnodes: an architecture for multiple file system types in sun unix** , USENIX 1986 (Summer)

虚拟文件系统（VFS）

- 虚拟文件系统
  - 实现FS接口和通用功能
- 物理文件系统
  - 磁盘布局、数据结构、磁盘空间管理、名字空间管理等

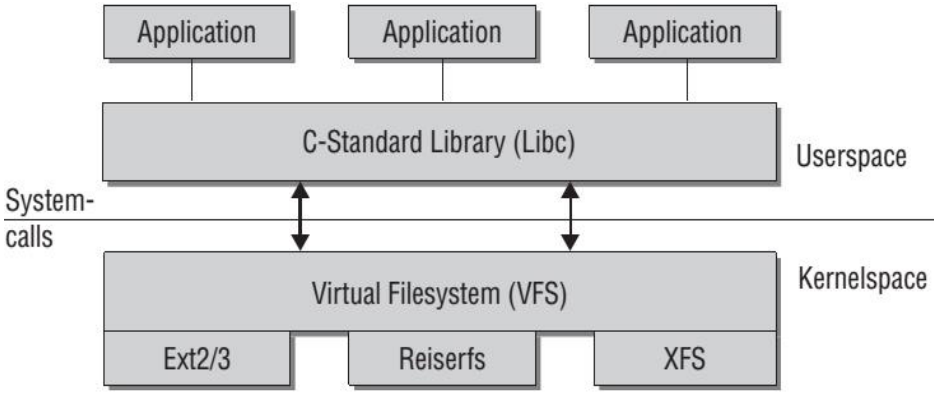

- 虚拟文件系统开关表
  - 用于物理文件系统的挂载与卸载
  - 每一种类型的文件系统有一个表项
    - 文件系统类型的名字
    - 初始化函数指针，用于mount
    - 清除函数指针，用于umount

FS主要数据结构

- i-node：描述文件/目录，也称为文件元数据
- dentry：目录项，记录文件和inode对应关系
- 打开文件表：记录进程打开的文件信息
- 超级块：描述文件系统基本信息

i-node

- i-node
  - 每个文件用一个i-node来描述
  - 文件元数据
  - ino: inode number，即i-node的ID，唯一标识一个文件 (在一个FS内)
- 文件属性信息
  - mode: 文件类型和访问权限
  - size: 文件大小
  - nlinks: 硬链接数，即指向该i-node的目录项个数
  - uid: 所有者的user ID
  - gid: 所有者的group ID
  - ctime: 文件创建的时间戳
  - atime: 上一次访问文件的时间戳
  - mtime: 上一次修改文件的时间戳

i-node

- 文件块的索引信息: 文件块的磁盘位置信息
  - <offset, count> → 磁盘上的位置
    - 文件块# → 磁盘逻辑块# LBN
  - 不同FS采用不同的索引机制

目录项（dentry）

- 目录内容为它所包含的所有子目录和文件的名字及其ino
  - 不包含子目录的内容
- 逻辑上，目录是一张映射表
  - 目录项（dentry）：文件名→ ino
- 物理上，目录是一个字节数组
  - 文件名不等长，数组每一项不等长
- 路径解析
  - 根据路径名，获得其ino
  - 逐级目录查找
  - 例子： “/home/os/fs01.ppt”
    - 在根目录下，查找”home”的ino
    - 在”home”目录下，查找”os”的ino
    - 在”os”目录下，查找”fs01.ppt”的ino
    - 根据”fs01.ppt”的ino，找到其数据块，进行读写操作

文件名	ino
.	125
..	1
vm01.ppt	137
homeworks	153
vm02.ppt	138
dev01.ppt	139
fs01.ppt	140

打开文件：fd=open(path, flags, mode)

- 打开文件表：Open-file table
  - 通过打开文件表（内存中）把进程与文件的i-node进行关联
  - 路径名解析和权限检查，得到path的ino，读出它的 i-node（保存在磁盘上）
  - 将磁盘i-node拷贝至一个内存i-node结构中，在打开文件表中增加一项，包含以下内容
    - 文件当前访问位置
    - 文件的reference count
    - 文件的访问模式
    - 内存inode结构的指针
    - …

打开文件：fd=open(pname, flags, mode)

- 打开文件表：Open-file table
  - 每个进程有一个文件描述符表（open file pointer array/file descriptor table）
    - 指针数组，每个指针指向打开文件表中的一项，表示一个打开文件
    - 该指针在文件描述符表中的下标，即文件描述符fd

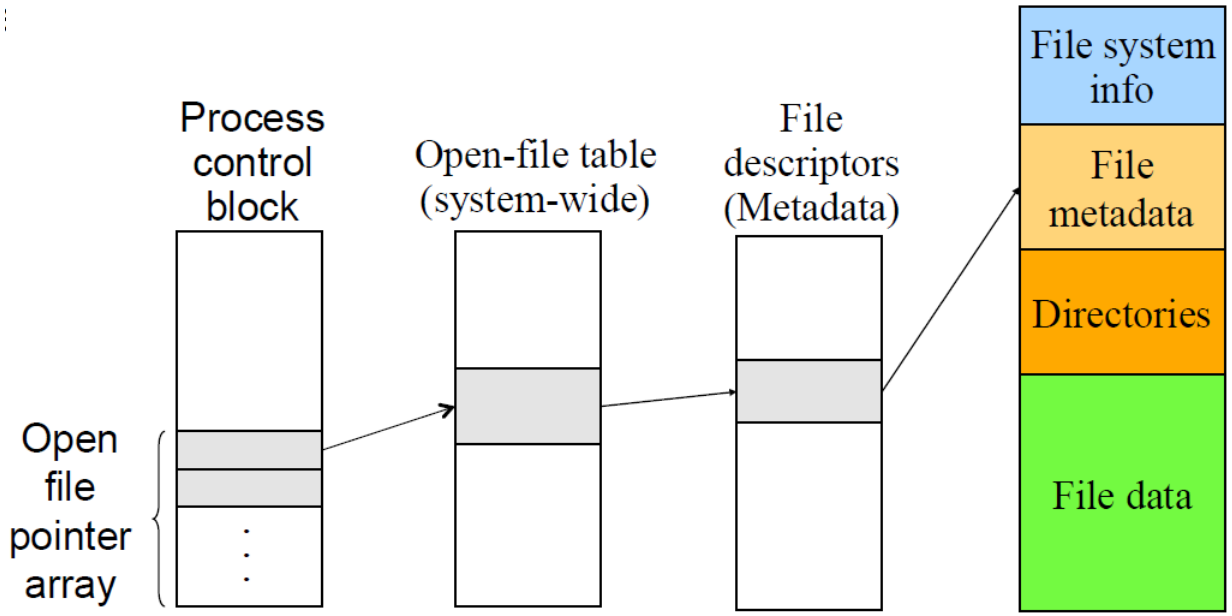

文件系统物理结构：磁盘布局

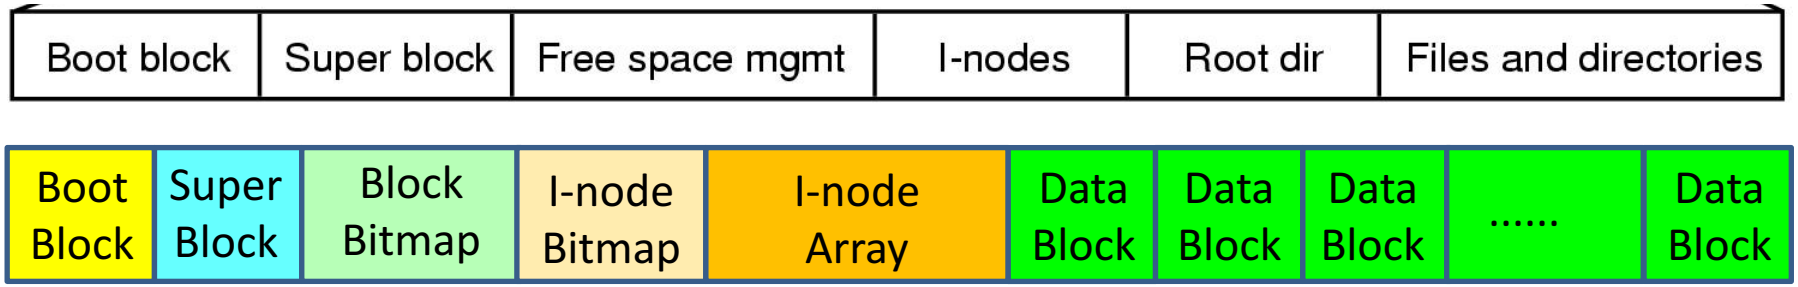

- 引导块
  - 启动OS的代码
- 超级块：定义一个FS
  - FS的相关信息
- 空闲空间管理相关的信息
- i-node表
  - 每个i-node描述一个文件或目录
- 数据块
  - 文件块或目录块

超级块

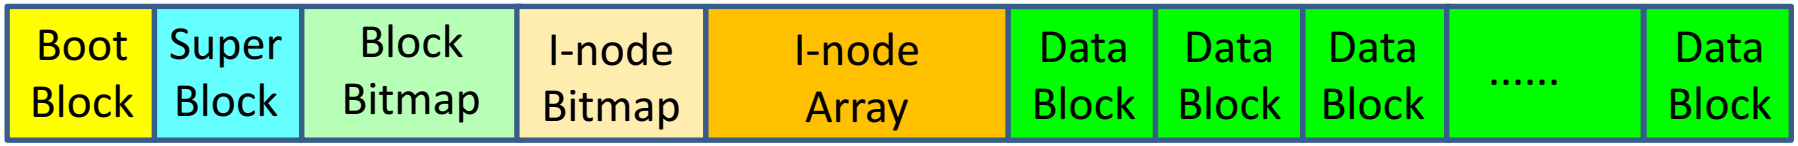

- 定义一个文件系统
  - 数据块的大小
  - i-node的大小
  - 数据块总数
  - i-node总数
  - 根目录ino
  - i-node表的起始地址
  - 空闲数据块（Block bitmap）起始地址
  - 空闲i-node（i-node bitmap）起始地址
- 当前状态
  - 数据块使用情况：已使用的块数、预留的块数、剩余的块数…
  - i-node使用情况：已使用的个数、剩余的个数…

FS相关的接口（系统命令）

- 创建文件系统　　mkfs：创建磁盘布局：初始化超级块、bitmap、根i-node等
- 删除文件系统　　rmfs
- 挂载(安装) FS　　mount –t fstype dev dir
- 卸载文件系统　　umount dev|dir
- 显示已安装FS　　mount 或者 mount dev|dir
- 同步文件系统　　sync (sync系统调用)
- 获取文件系统属性 df (statfs系统调用)
- ……
- 创建、删除、安装、卸载只允许特权用户调用

mount

例子：mount –t ext4 /dev/sdb /home/os

- 前提
  - 文件系统类型ext4必须事先已注册到内核
  - 挂载目录/home/os必须已经创建好
- 步骤
  - 根据文件系统类型，查VFS开关表，找到该ext4类型FS的初始化函数，即ext4_mount()
  - 调用ext4_mount
    - 读取超级块
    - 读取根目录i-node
  - 初始化一些内存数据结构：超级块、根i-node等

总结

- FS名字空间是由目录和文件构成的树形层次化结构
  - 文件是无结构的命名字节数组
  - 目录是一种特殊的文件，包含文件和子目录的命名集合
  - 文件和目录有各自的访问接口
- FS结构
  - 虚拟文件系统：提供统一的访问接口，对接不同的物理文件系统
  - 物理文件系统：实际管理磁盘、文件、目录等

总结

- FS主要数据结构
  - 超级块：记录一个文件系统的基本信息
  - i-node：定义一个文件/目录，根据ino定位inode的磁盘位置
  - 目录项（dentry）：目录文件中的内容，记录文件名→ino的映射关系
  - 打开文件表：记录目前打开文件的信息，例如访问位置、访问模式，内存inode指针等
  - 超级块：记录文件系统的基本信息