中国科学院大学
University of Chinese Academy of Sciences

虚存和地址转换

中国科学院大学计算机与控制学院
中国科学院计算技术研究所

2019-11-11

内容提要

- 计算机存储体系结构
- 虚存
  - 虚拟化
  - 保护
- 地址映射
  - 基址+长度
  - 分段
  - 分页
- TLB

现有计算机体系结构

- 冯·诺伊曼结构

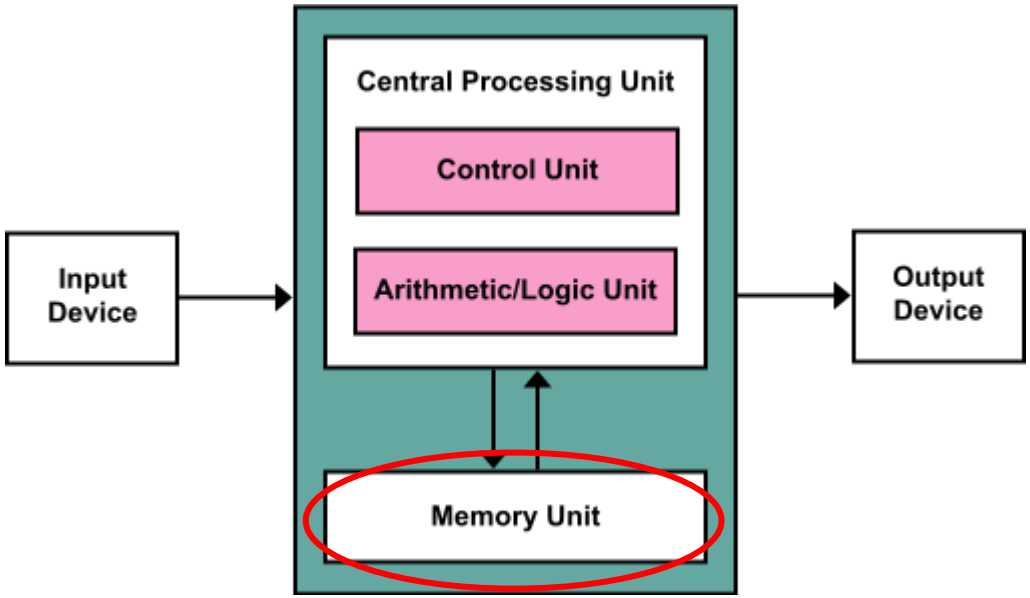

Source： https://en.wikipedia.org/wiki/Von_Neumann_architecture

《天才的拓荒者——冯•诺依曼传》
[美] 麦克雷，上海科技出版社
2008年12月

Jonh von Neumann, **First Draft of a Report on the EDVAC**, 1945

现有计算机体系结构

- 层次化存储结构

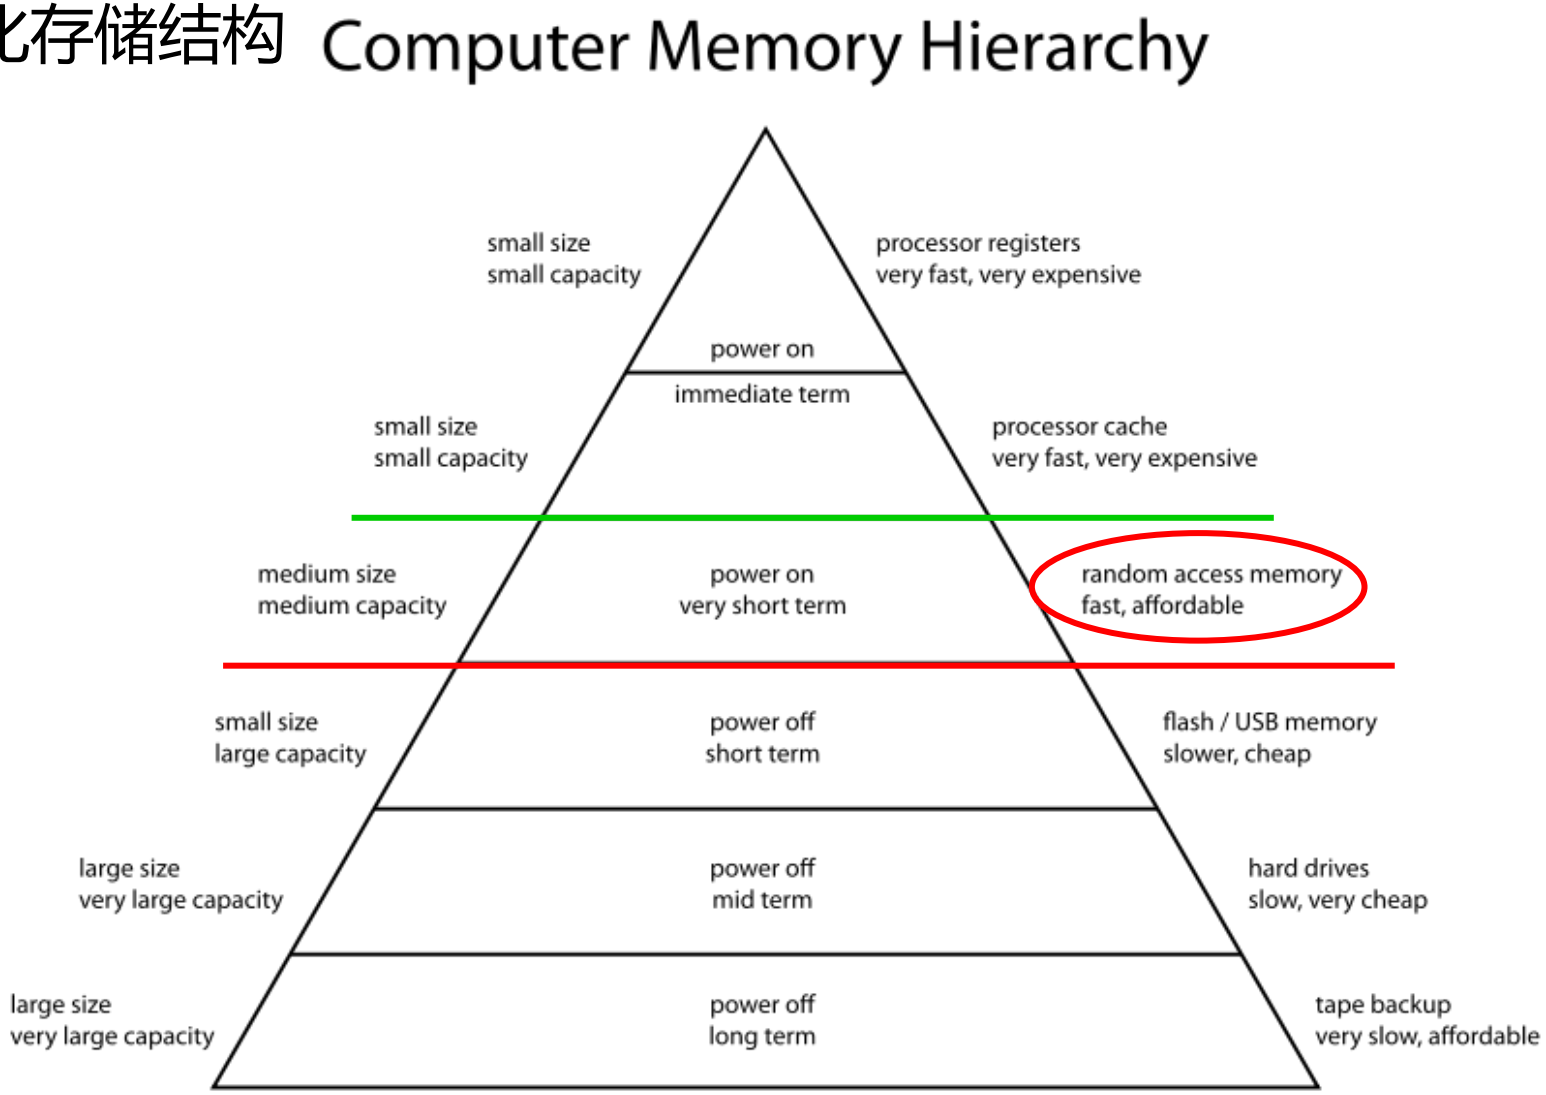

图片来源：https://en.wikipedia.org/wiki/Memory_hierarchy

现有计算机体系结构

- 内存DRAM：快，但贵，容量小，易失性
- 外存磁盘：持久化，便宜，容量大，但慢

现有计算机系统存储层次	延迟	容量
Register	0.4~1ns	2K
L1 cache	1~4ns	16~32K
L2 cache	5~10ns	64~256K
L3 cache	20~40ns	1~32M
Memory	100ns	4~16G
Flash-based SSD	20~100us	1~4T
Hard disk	3~5ms	1~4T

问题

- 如何高效地使用内存空间?

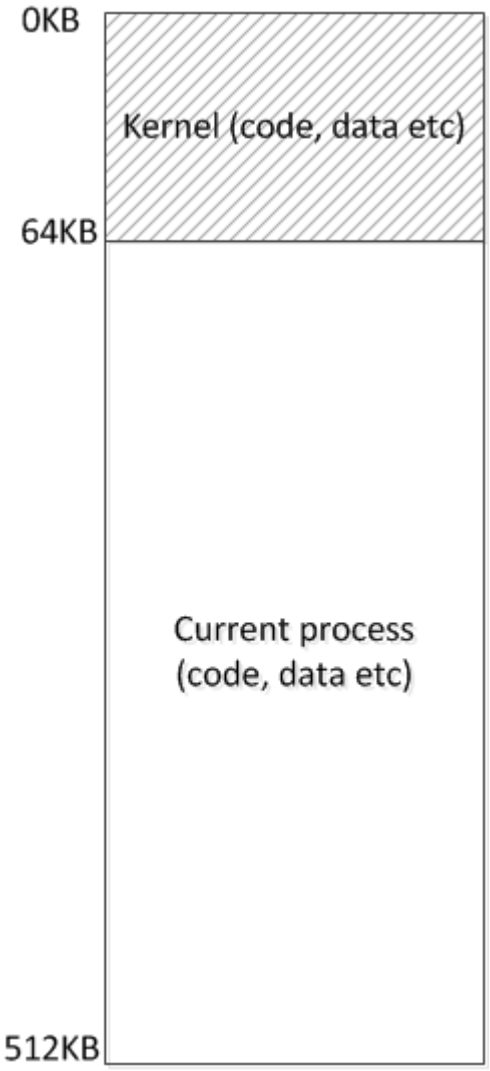

Multiprogramming
& Time sharing

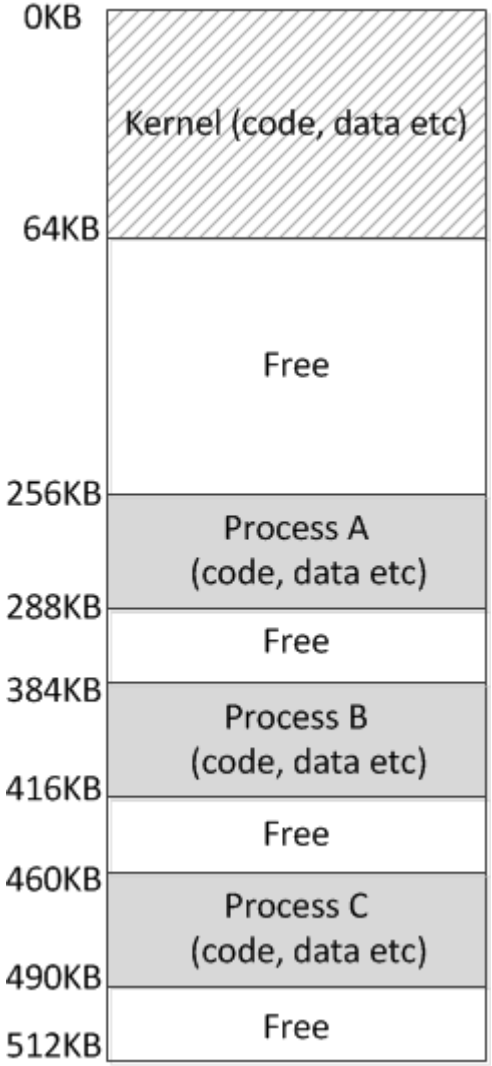

最简单的系统

- 只有物理内存
  - 应用程序直接使用物理内存
- 例子：运行3个进程
  - Email，browser, gcc
- 可能会发生以下这些情况
  - email发生地址错误
  - browser对地址0x7050写
  - gcc需要扩展内存
  - browser需要比物理内存更多的内存

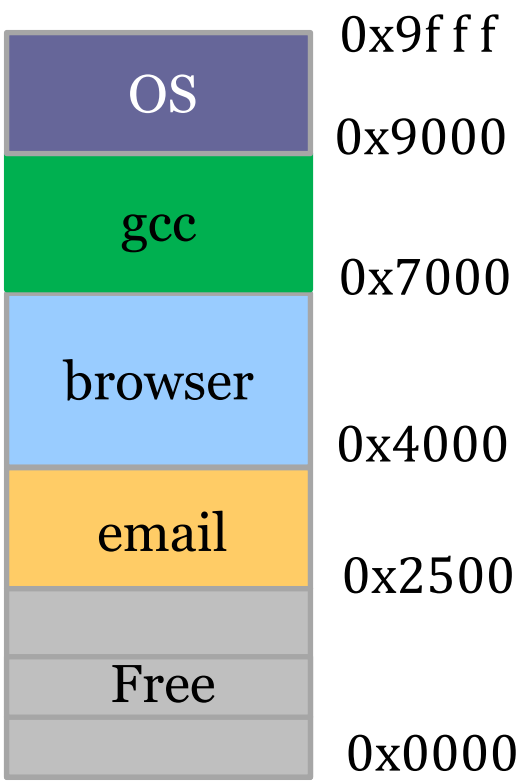

最简单的系统

- 物理内存静态划分（研讨课实现）

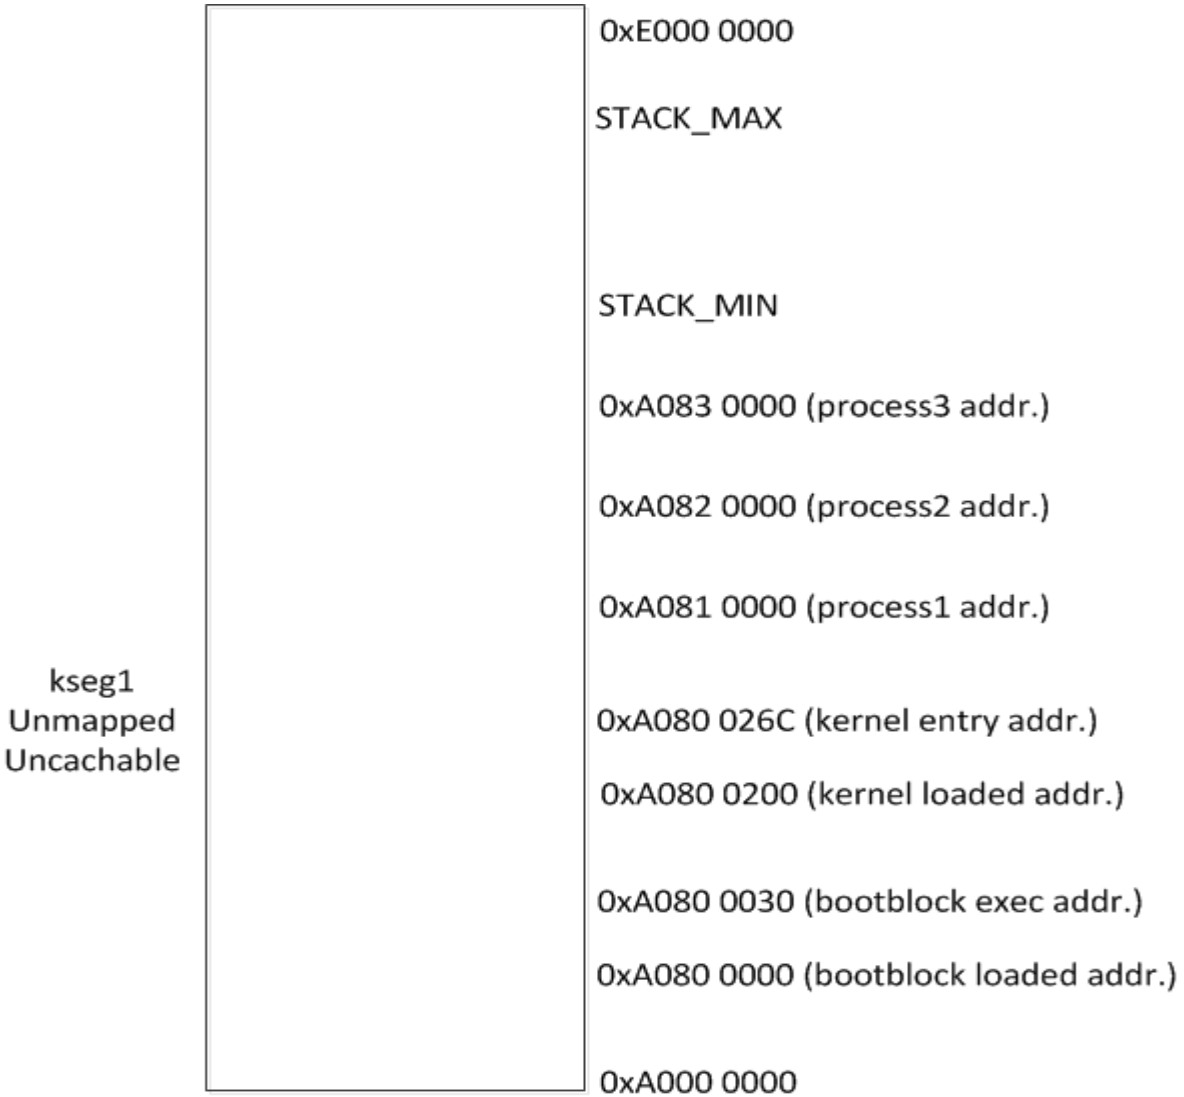

需求一：进程保护

- 一个进程出错不能影响其它进程
- 对每次内存访问都进行检查，只允许合法的内存访问
  - 每个进程的每个load和store指令、隐式访存指令

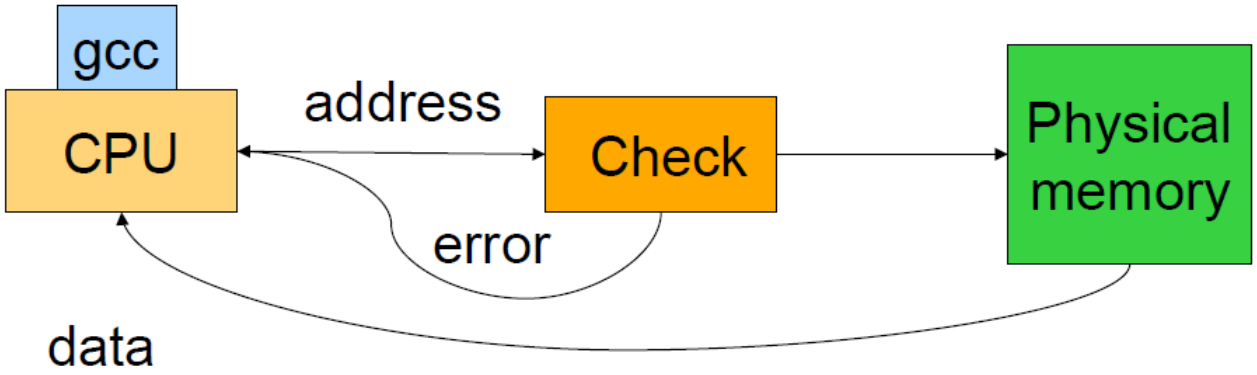

需求二：扩展内存和应用透明

- 一个进程必须能运行在不同的物理内存区域上
- 一个进程必须能运行在不同的物理内存大小上

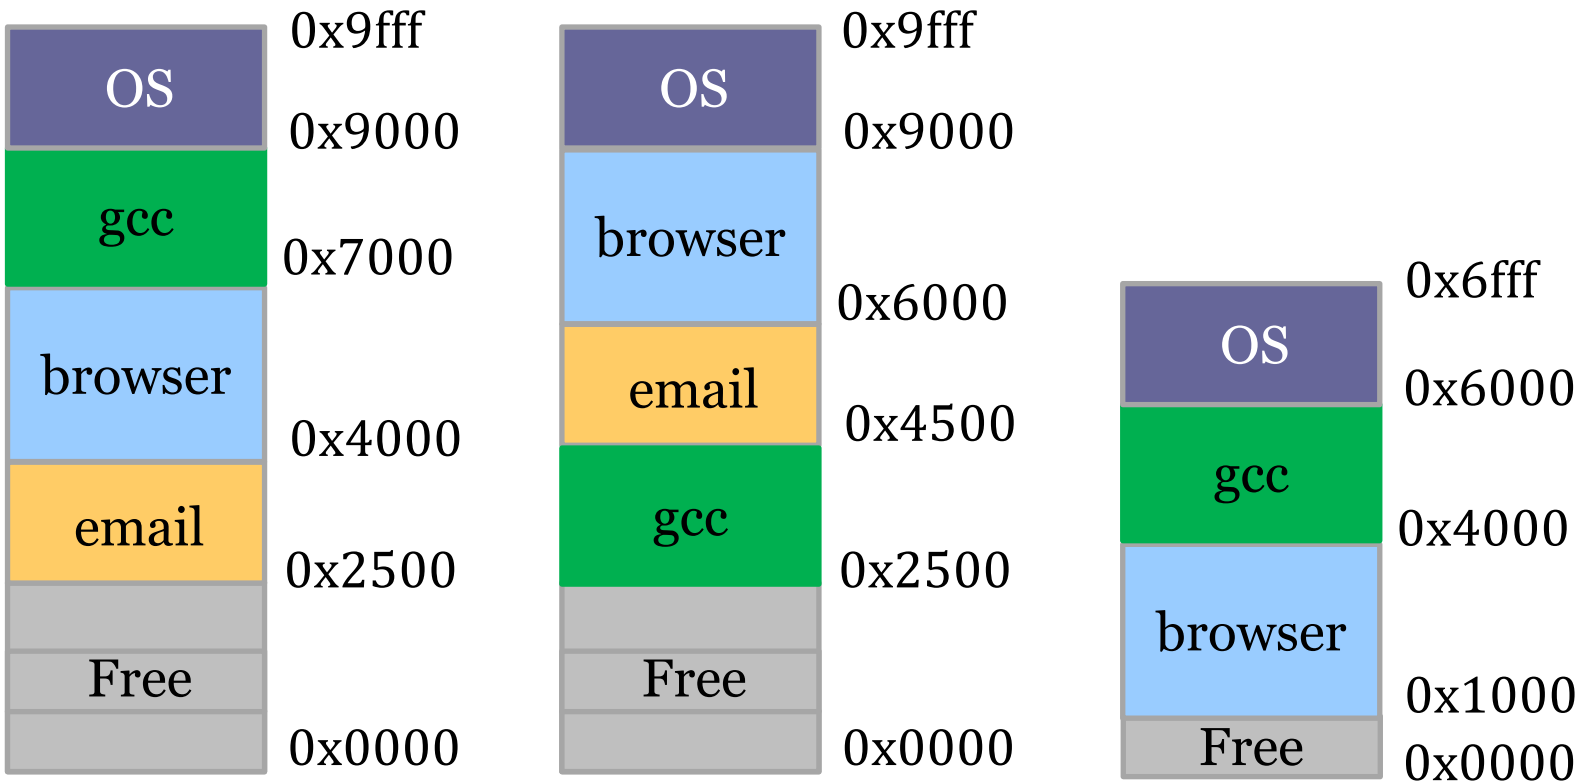

问题

- 如何高效地使用内存空间?
  - 目标1：同时运行多个进程
    - 系统运行的进程越多越好
  - 目标2：地址空间足够大
    - 一个大进程，其大小超过物理内存
    - 很多小进程，但它们的总大小超过物理内存
  - 目标3：保护
    - 一个用户进程不能读取、更不能修改另一个用户进程的内存
    - 用户进程不能破坏内核的内存

解决方案

- 基本内存抽象
  - 地址空间：进程的内存视图 → 虚拟内存
  - 透明使用，高效访问，安全保护
- 虚拟内存 vs 虚拟CPU
  - 虚拟CPU
    - 进程不与CPU绑定，可以迁移到任一CPU
    - 进程执行时，以为“独占”CPU
    - 进程CPU状态与切换：上下文
  - 虚拟内存
    - 进程数据不与内存绑定，可以迁移到任意的内存/磁盘位置
    - 进程执行时，以为“独占”内存
    - 进程内存状态：？

内容提要

- 计算机存储体系结构
- 虚存
  - 虚拟化
  - 保护
- 地址映射
  - 基址+长度
  - 分段
  - 分页
- TLB

虚拟内存（Virtual Memory）

- 独立的（进程）地址空间
  - 给每个进程提供一个很大的、静态的“虚拟”地址空间
- 虚实地址转换
  - 进程运行时，每次访存通过地址转换（relocate）获得实际的物理内存地址
- 磁盘作为内存的延展（**磁盘交换区**）
  - 按需加载：只装载部分地址空间至内存

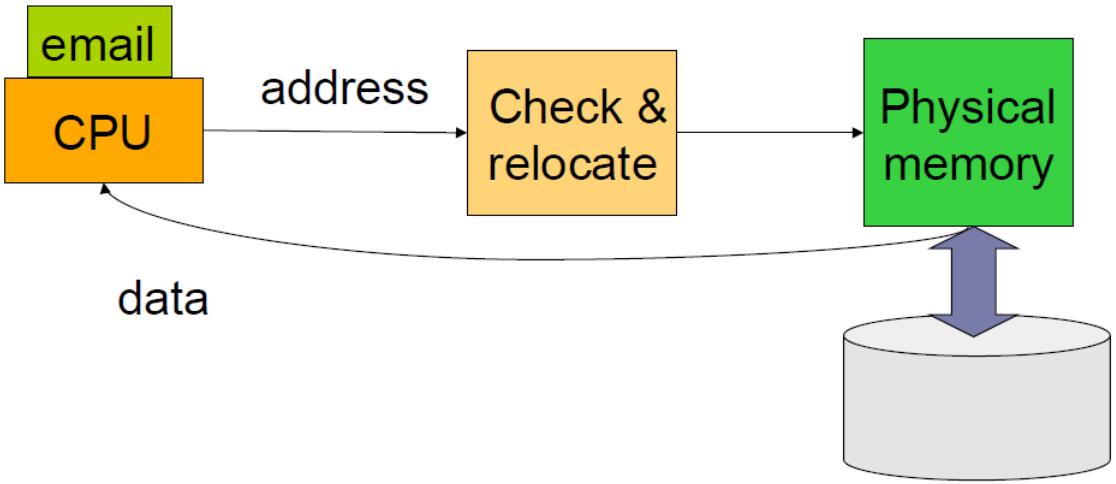

地址空间

- 独立的进程地址空间 [0, max-1]
  - 程序员看到的是虚地址
- 运行时装载部分地址空间
- 每次访存：虚地址→物理地址
  - CPU看到的是虚地址
  - 进程看到的是虚地址
  - 内存与I/O设备看到的是物理地址
- 如果访问到未装载的地址空间
  - 通知OS将它加载进内存

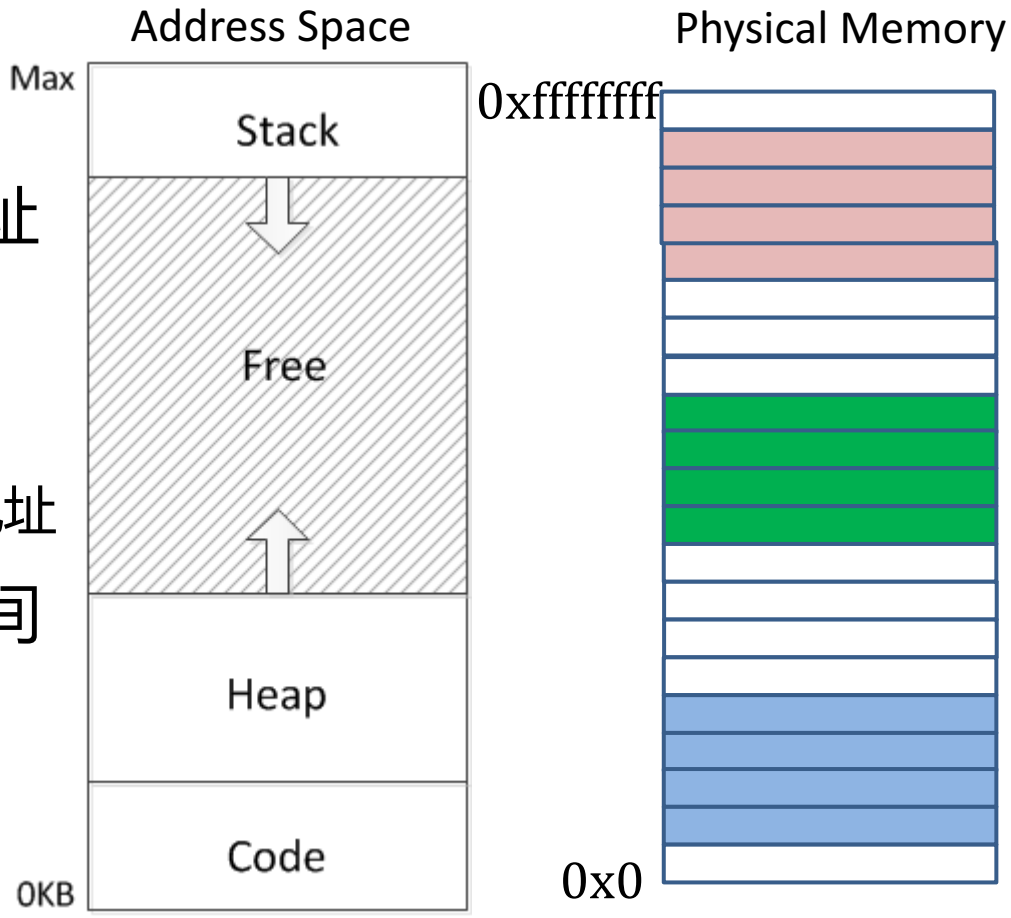

虚存的好处

- 灵活
  - 进程在执行时才放进内存，一部分在内存 & 另一部分在磁盘
- 简单
  - 进程的内存访问变得非常简单
- 高效
  - 20/80原则：20%的地址空间承担80%的访问
  - 将20%地址空间放进物理内存
- 安全
  - 虚实地址转换时进行安全检查，防止非法访问

虚存设计

- 设计问题
  - 如何进行地址转换？
  - 如何划分内存？
  - 如何实施保护？

内容提要

- 计算机存储体系结构
- 虚存
  - 虚拟化
  - 保护
- 地址映射
  - 基址+长度
  - 分段
  - 分页
- TLB

地址转换

- 目标
  - 隐式：对每个内存访问，转换是隐式的
  - 快速：命中内存时必须非常快
  - 例外：不命中时触发一个例外
  - 保护：能够隔离用户进程的错误

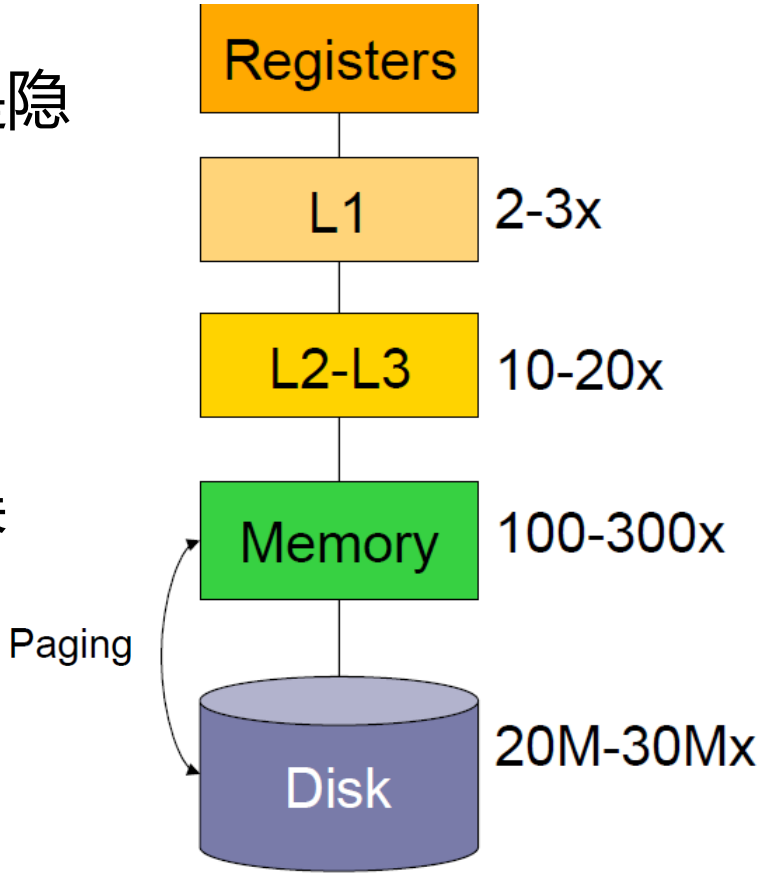

地址映射和粒度

- 需要某种“映射”机制
  - 把虚地址空间（大）的内容 放进 物理内存空间（小）
- 映射必须有合适的粒度
  - 粒度决定灵活性
  - 大粒度映射可能造成内存浪费
  - 细粒度映射需要更多的映射信息（trade-off）
- 极端情况
  - 字节粒度映射：映射表过大
  - 进程粒度映射：内存浪费

基址+长度 (Cray-1采用的方法)

- **连续分配**
  - 为每个进程分配地址连续的内存
  - 用一个二元组来限定其内存区域：<base, bound>
- 保护
  - 一个进程只能访问 [base, base + bound] 区间的内存
- 上下文切换
  - 保存/恢复基址寄存器及上限寄存器
- 好处
  - 简单：映射时将虚地址与基址相加
  - 支持换出(swapping)：多进程并发执行
- 坏处
  - 外部碎片（进程间的碎片）
  - 难以支持进程增大
  - 难以共享内存

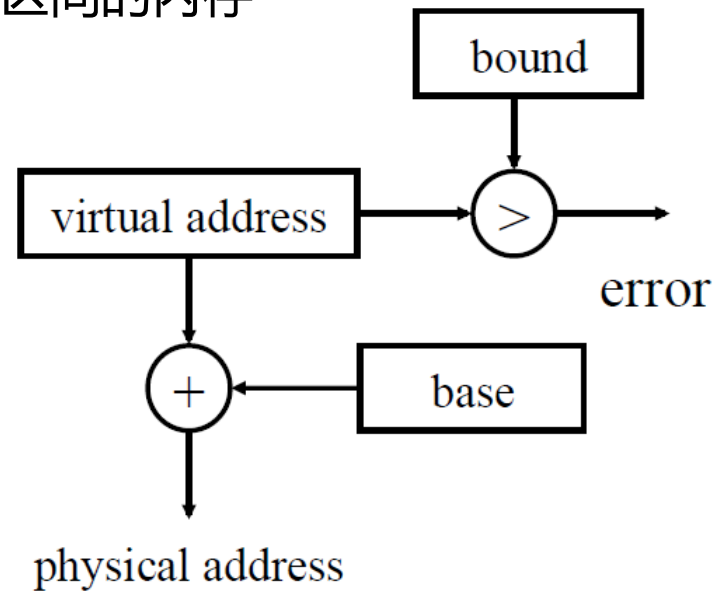

内存碎片

- 碎片问题
  - 随着进程的换入与换出，内存产生很多空洞（未使用的小区域）

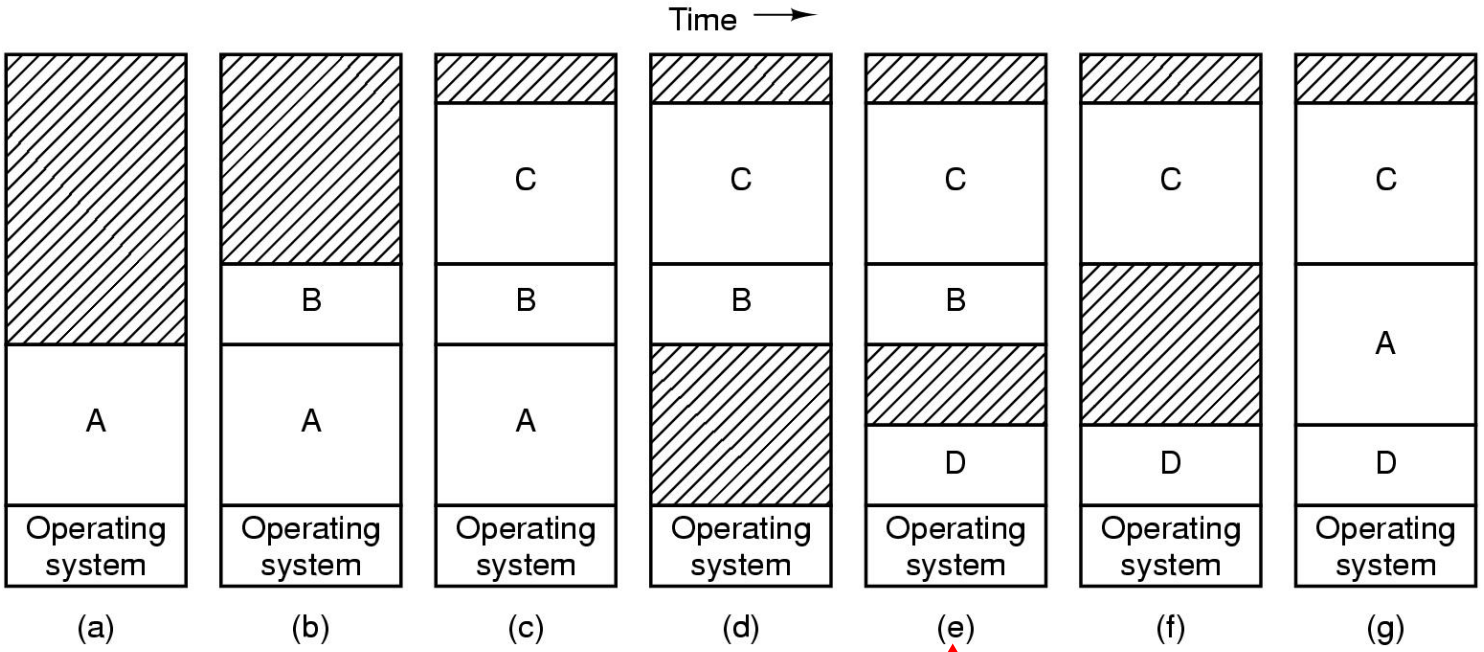

如果此时A程序要运行
- 要么把另一个进程换出，如(f)(g)所示
- 要么进行碎片聚合（memory compaction）

地址转换实现

- 地址类别
  - CPU发出的是虚地址
  - 内存和I/O设备接收的是物理地址
- MMU职责
  - Memory Management Unit，负责虚地址到物理地址转换的硬件单元
  - 通常在片内实现，每个CPU有一个base寄存器和一个register寄存器
  - 虚存地址转换为物理地址，每条load和store指令都需要地址转换
  - 内存保护，检查地址是否有效
  - 特殊指令操作base和bound寄存器

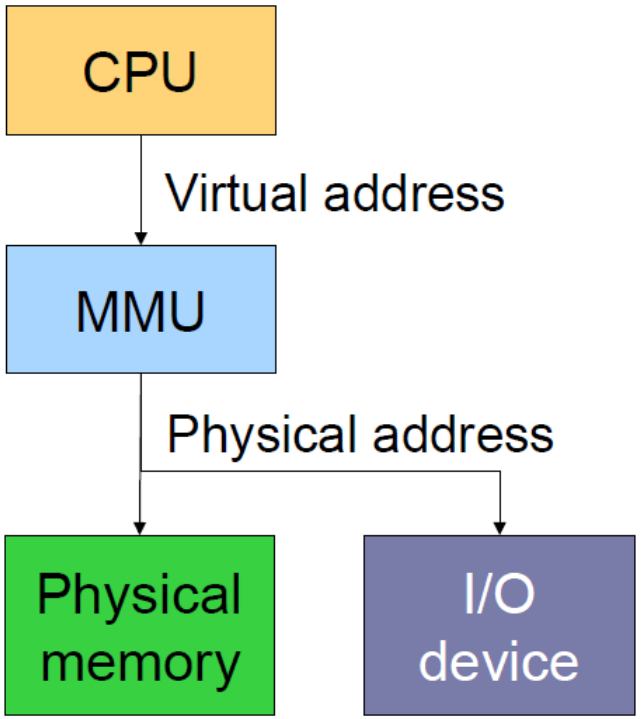

地址转换实现

- 操作系统职责
  - 内存管理
    - 新进程分配空间，结束的进程回收空间
  - 进程切换时base-bound管理
    - 保存当前进程的base-bound值，设置即将运行进程的base-bound值
  - 异常处理
    - 内存越界访问、无效地址（例如base-bound不存在）等

分段

- **不连续分配**
  - 把程序逻辑上划分为若干段：代码、全局变量、栈、…
  - 每个段分配连续内存，段间不必连续
  - 每个进程有一张段表：(seg, size)
  - 每个段采用基址+长度

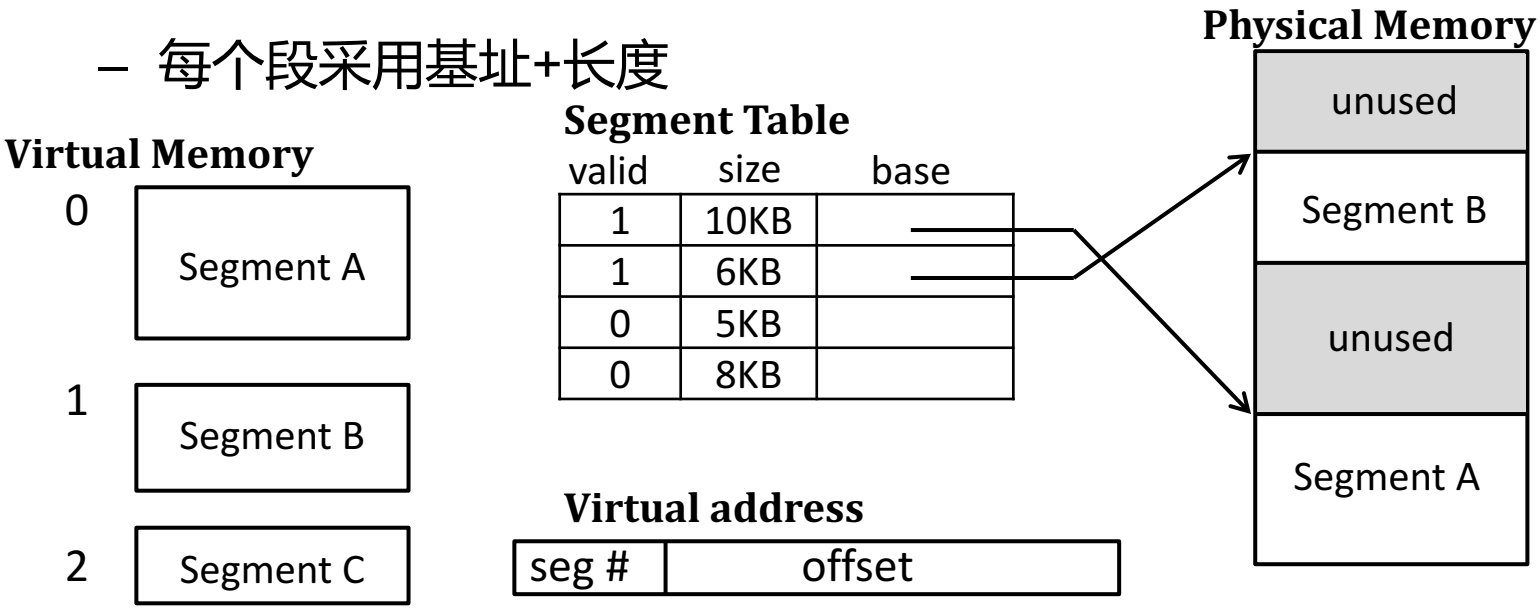

如果访问地址的offset>= 段size，则memory violation
如果访问地址所在seg#的valid为0，则segment fault

分段

- 保护
  - 每个段有(nil, read, write, exec)
- 上下文切换
  - 保存/恢复 段表和指向段表的内核指针
- 好处
  - 相比基址+长度，资源使用更高效
  - 易共享
- 不足
  - 管理复杂
  - 外部碎片（段间碎片）

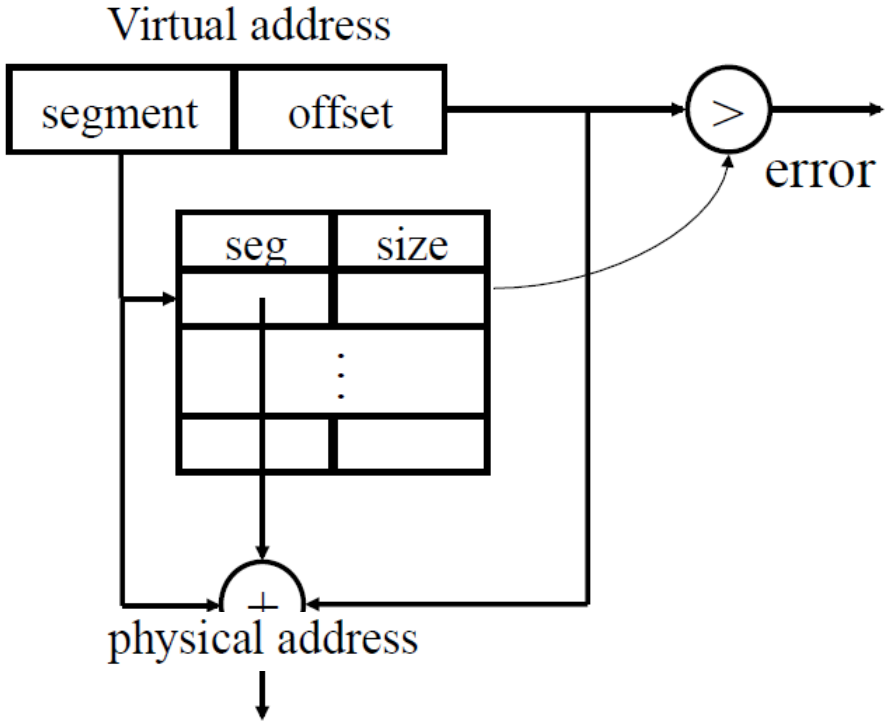

分页

- 分页机制
  - 使用固定大小的映射单元
  - 把虚存划分成固定大小的单元（称为页，page）
  - 把物理内存划分成同样大小的单元（称为页框，page frame）
  - 按需加载

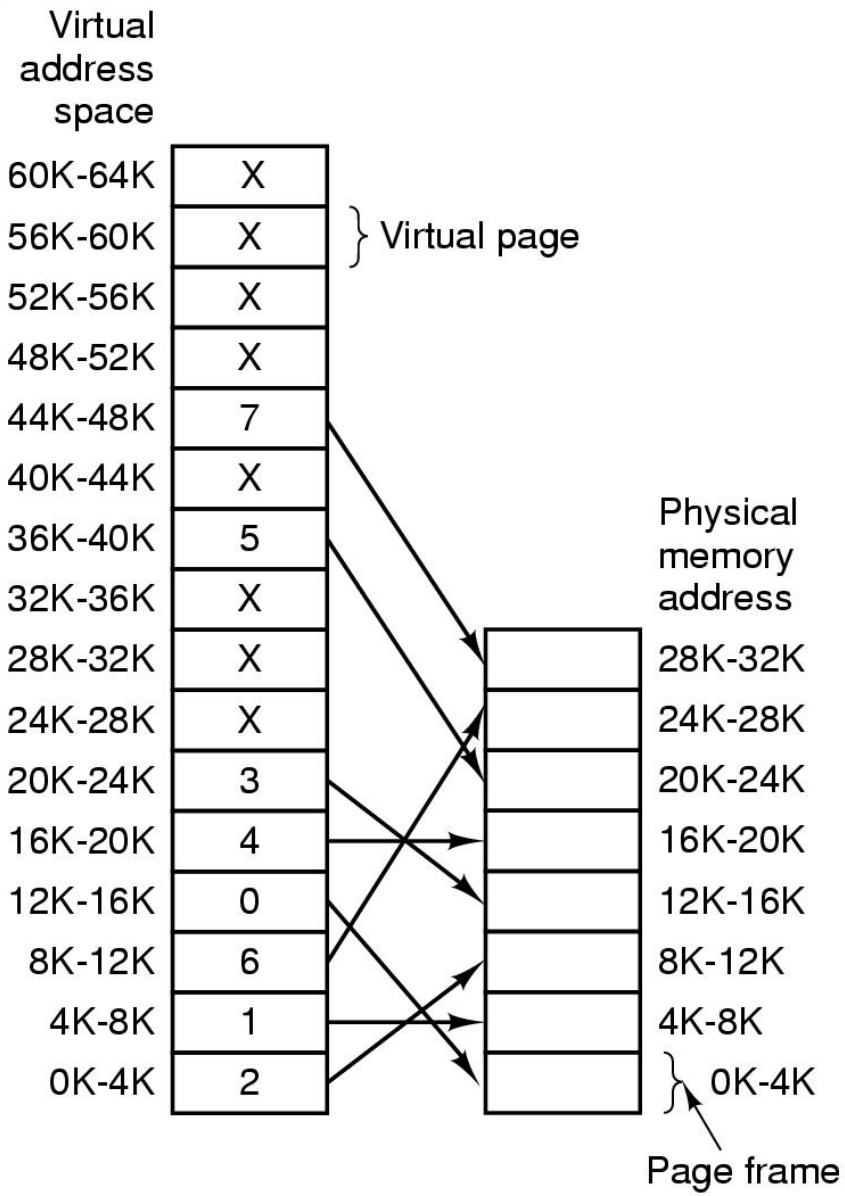

分页

- 用**页表**来记录映射
  - 虚页 → 物理页
- 每个表项有若干控制位
  - 按页保护（read, write, exe)
- 上下文切换
  - 与分段类似：保存/恢复页表及其地址
- 好处
  - 分配简单
  - 易共享
- 坏处
  - 页表很大
  - 进程地址空间有很多空洞：对应的页表项无用

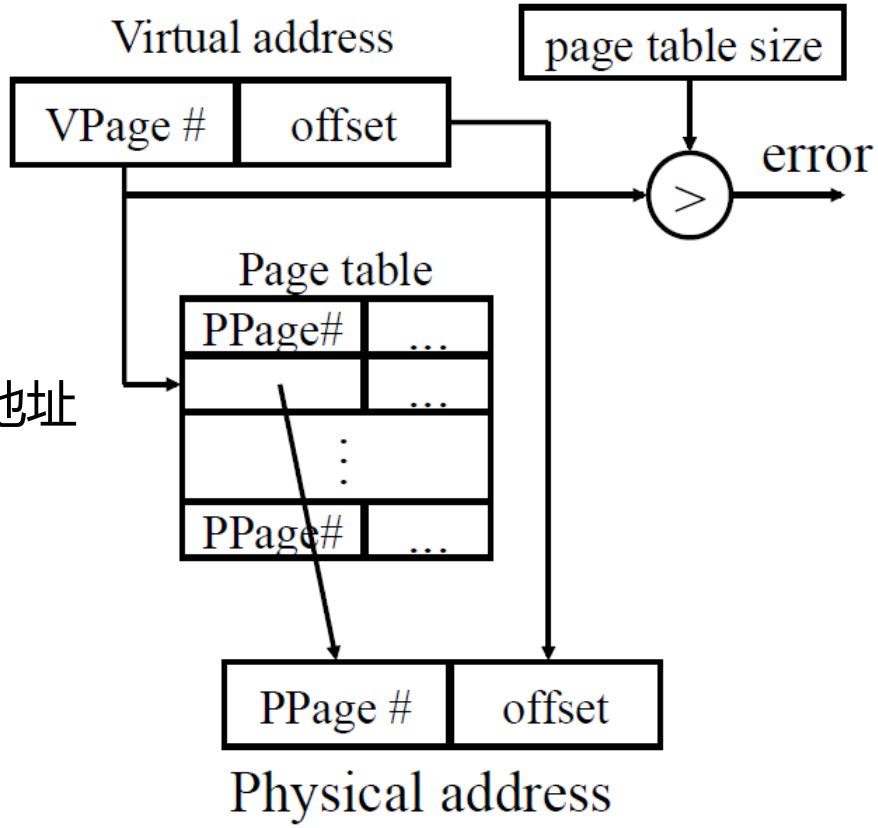

页表项

- 表达一个映射关系（Page Table Entry，PTE）：虚页号→物理页号

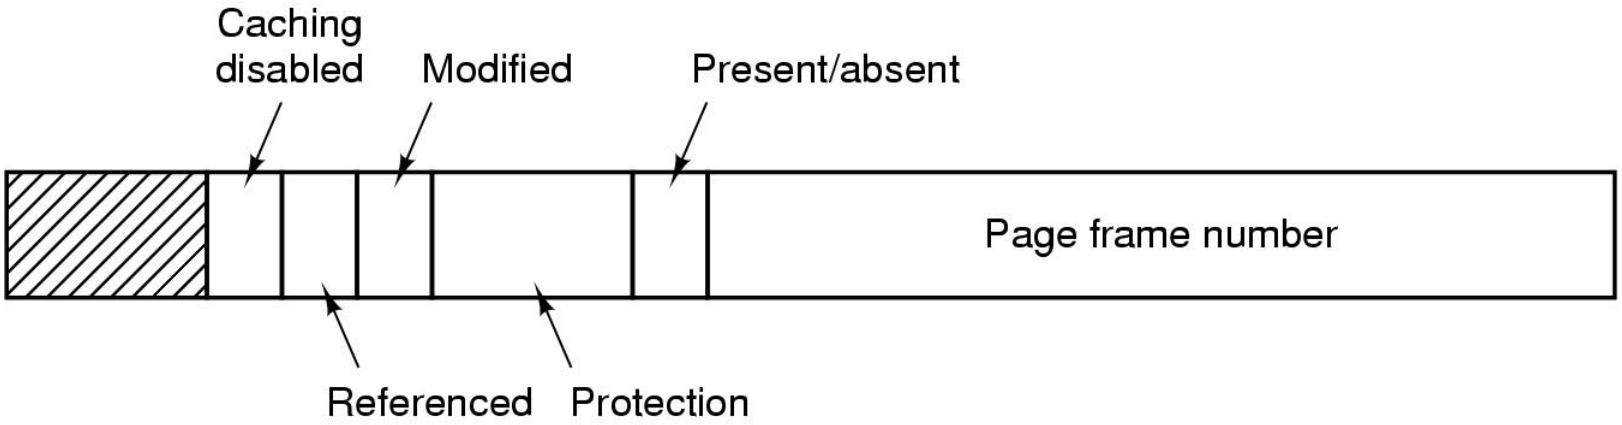

- PP#
- 控制位
  - 有效位(Valid)：1位， 标识该页在内存(Present)或不在内存(absent)，V位
  - 保护位(Protection)：1~3位，read, write, exe
  - 修改位(Modified)：1位，M位
  - 访问位(Referenced)：1位，R位
  - 缓存位(Cacheable)：1位（讲设备时会用到）

线性页表

- 线性页表

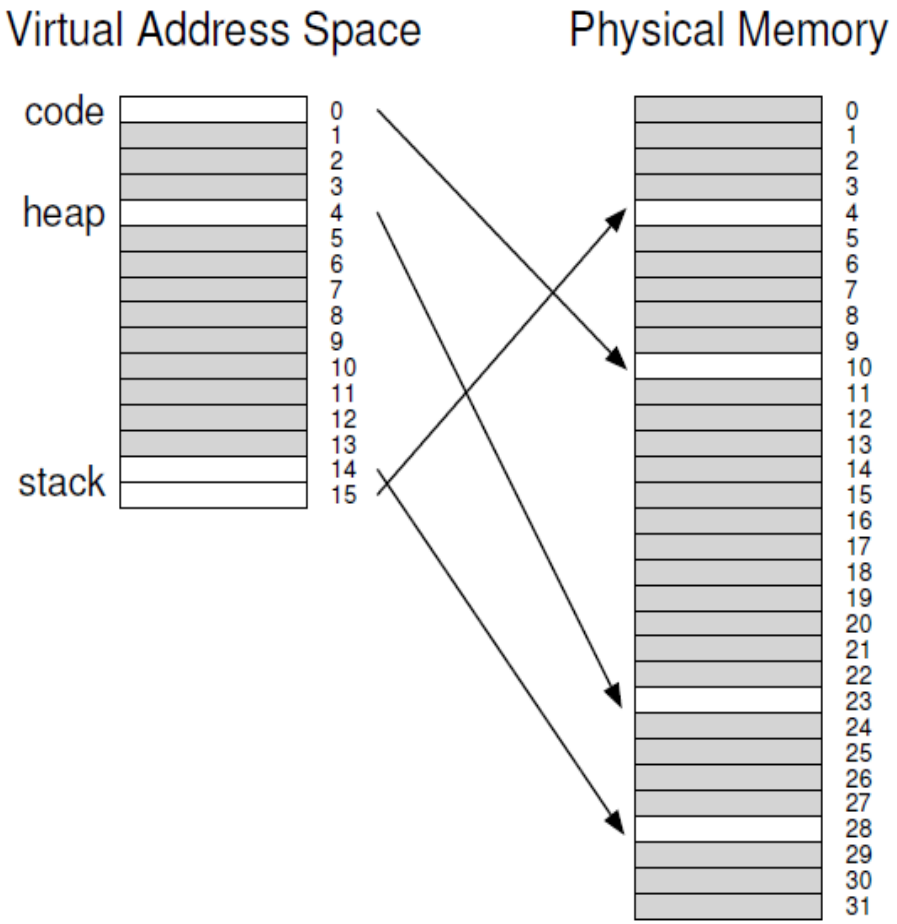

PFN	valid	prot	present	dirty
10	1	r-x	1	0
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
23	1	rw-	1	1
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
-	0	—	-	-
28	1	rw-	1	1
4	1	rw-	1	1

页表项（PTE）数量

- 假设4KB的页
  - 低12位为页内偏移
- 32-位地址的机器
  - 每个进程的页表有2^{20}个页表项，每一项4B（~4MiB）
  - 页表所需内存空间 = 进程数量 x 4MB
  - 如果有10K个进程，内存放不下所有的页表
- 64-位地址的机器
  - 每个进程的页表有2^{52}个页表项
  - 页表所需内存空间 = 进程数量 x 2^{52}
  - 一个进程的页表可能磁盘都存不下（2^{52} PTEs = 16PiBytes!）

分段+分页

- 先将进程划分为若干段
- 每个段采用分页
- 段表记录它的页表地址
- 不足
  - 分段的不足仍然存在

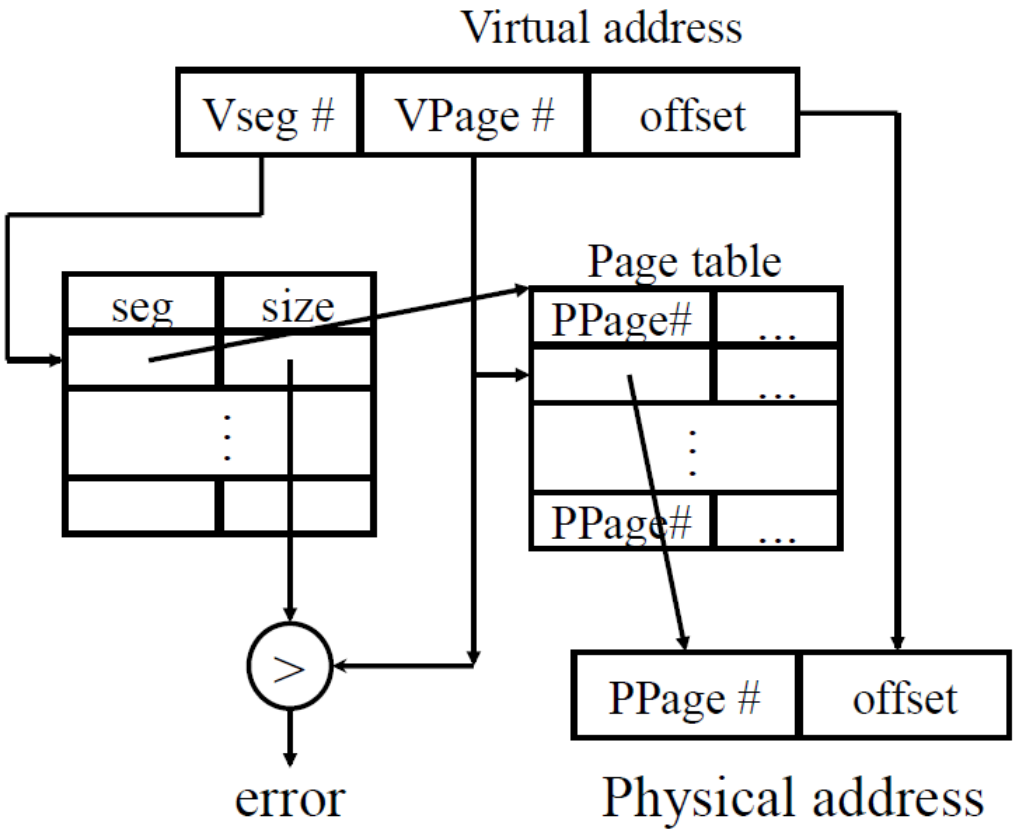

多级页表

- 虚地址除去offset之外的部分划分为多个段
  - 每段对应一级页表
  - 多个页表
- 好处
  - 节省空间
- 分段+分页和多级页表
  - 区别？

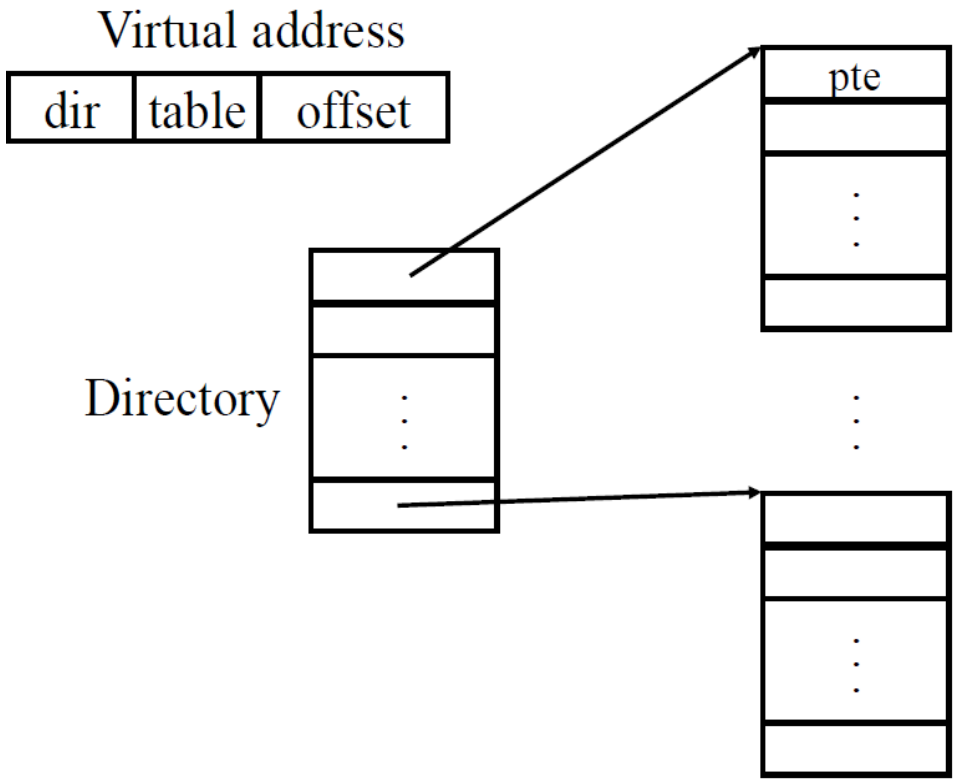

示例：两级页表

虚地址：0X00403004 （32位虚地址空间，4KiB/页）

0000 0000 0100 0000 0011 0000 0000 0100

PT1=1　　PT2=3　　Offset=4

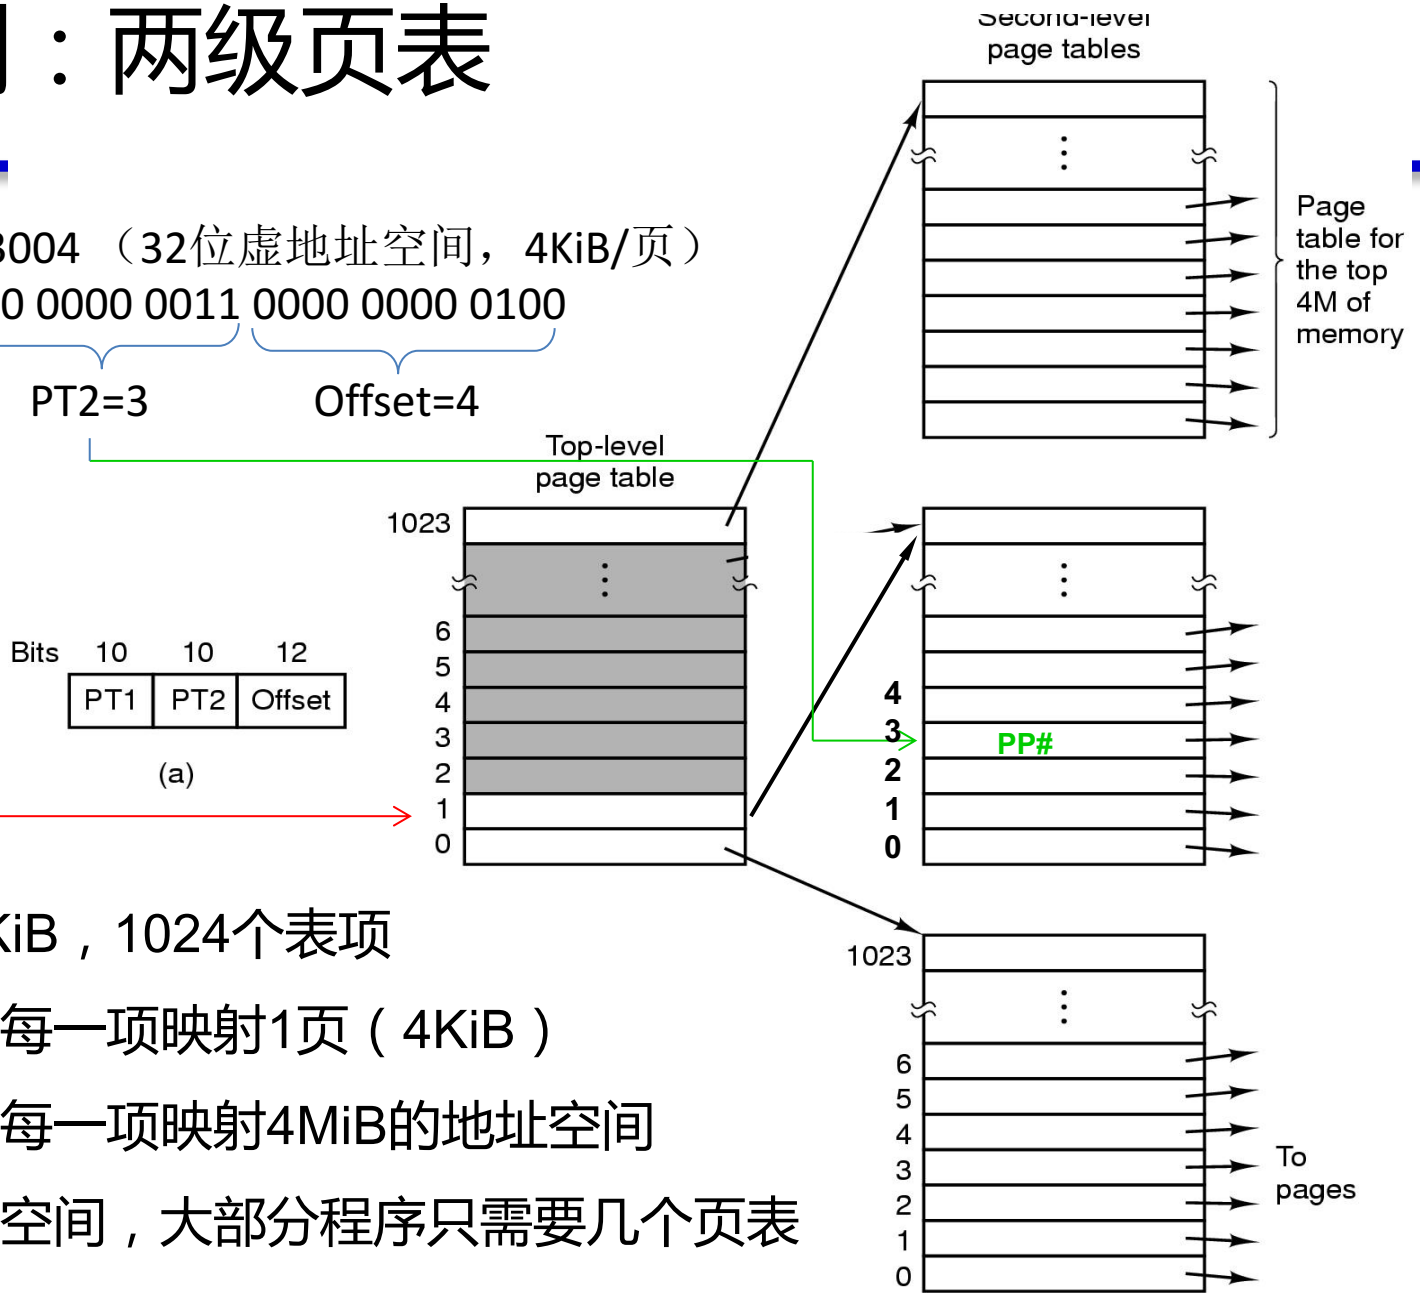

- 每个页表4KiB，1024个表项
- 下级页表的每一项映射1页（4KiB）
- 上级页表的每一项映射4MiB的地址空间
- 对于大地址空间，大部分程序只需要几个页表

反向页表

- 64位地址空间，4KiB页，总共有2^{52}个页
- 256MiB物理内存，总共有2^{16}个页框
- 按物理页索引，记录每个物理页对应的进程ID及虚页

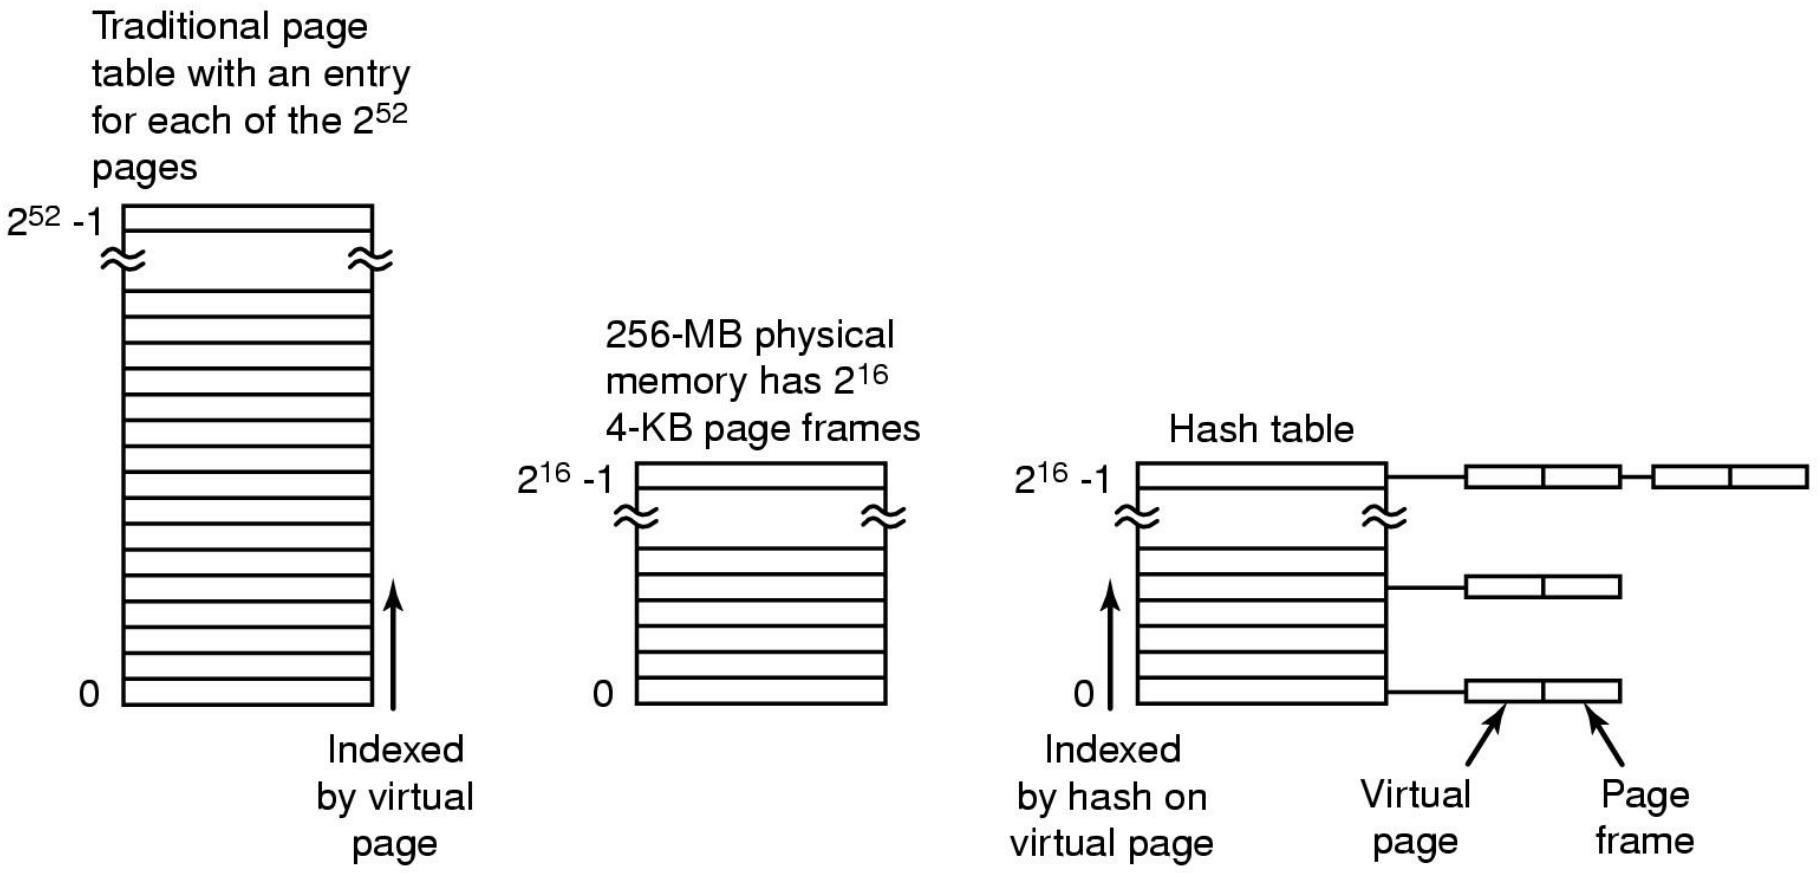

反向页表

- 主要思想
  - 每个物理页一个PTE
  - 地址转换：哈希查找
  - Hash(Vpage, pid) → Ppage#
- 好处
  - 页表大小与地址空间大小无关
只与物理内存大小有关
  - 对于大地址空间，页表较小
- 坏处
  - 查找难（哈希冲突）
  - 管理哈希链等的开销

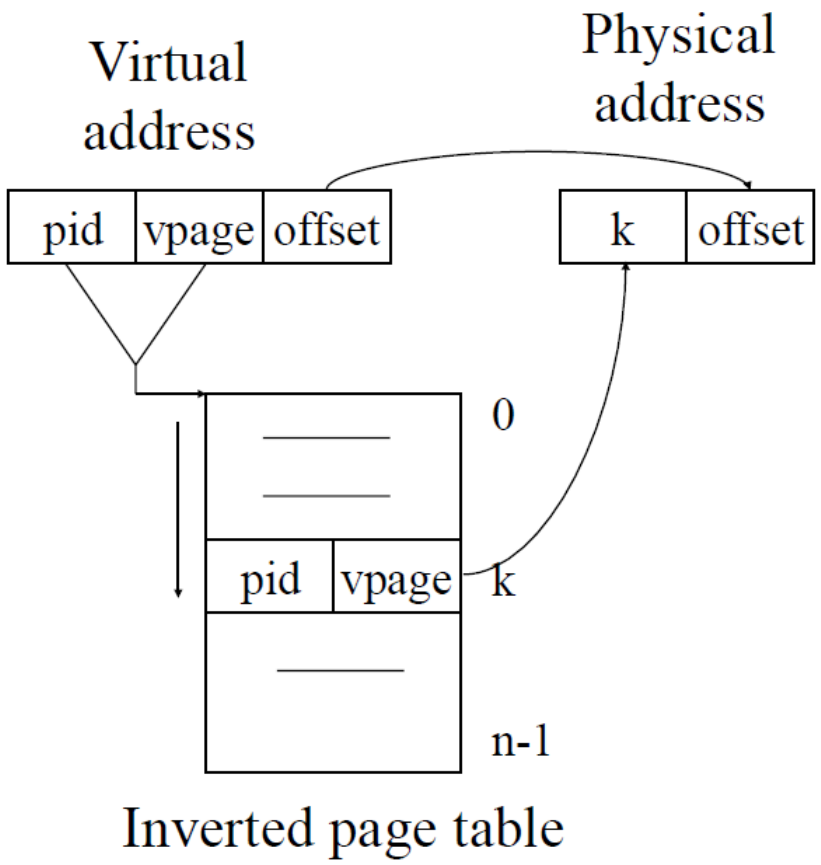

内容提要

- 计算机存储体系结构
- 虚存
  - 虚拟化
  - 保护
- 地址映射
  - 基址+长度
  - 分段
  - 分页
- TLB

加速地址转换

- 程序只知道虚地址
  - 每个程序或进程的地址空间是 [0, max-1]
- 每个虚地址必须进行转换
  - 可能需要逐级查找多级页表
  - 页表保存在内存中，一个内存访问变成多个内存访问
- 解决办法
  - 用速度更快的部件来缓存使用最频繁的那部分页表项

缓存机制

- 缓存是计算机系统的一种重要机制
  - 层次化存储体系结构
  - 用更快速的存储设备保存数据，以免每次从低速存储设备中读取数据
    - 缓存空间小于总数据量大小
    - 缓存命中时，从缓存中读取数据
    - 未命中时，从低速设备读取数据
  - 缓存满时，替换现有数据
  - CPU cache，page cache

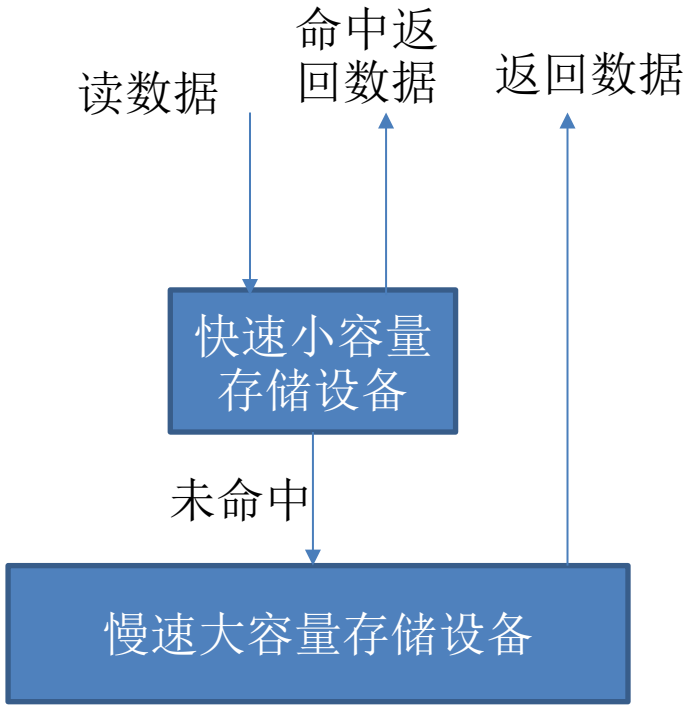

TLB: Translation Look-aside Buffer

- 一种页表的缓存机制

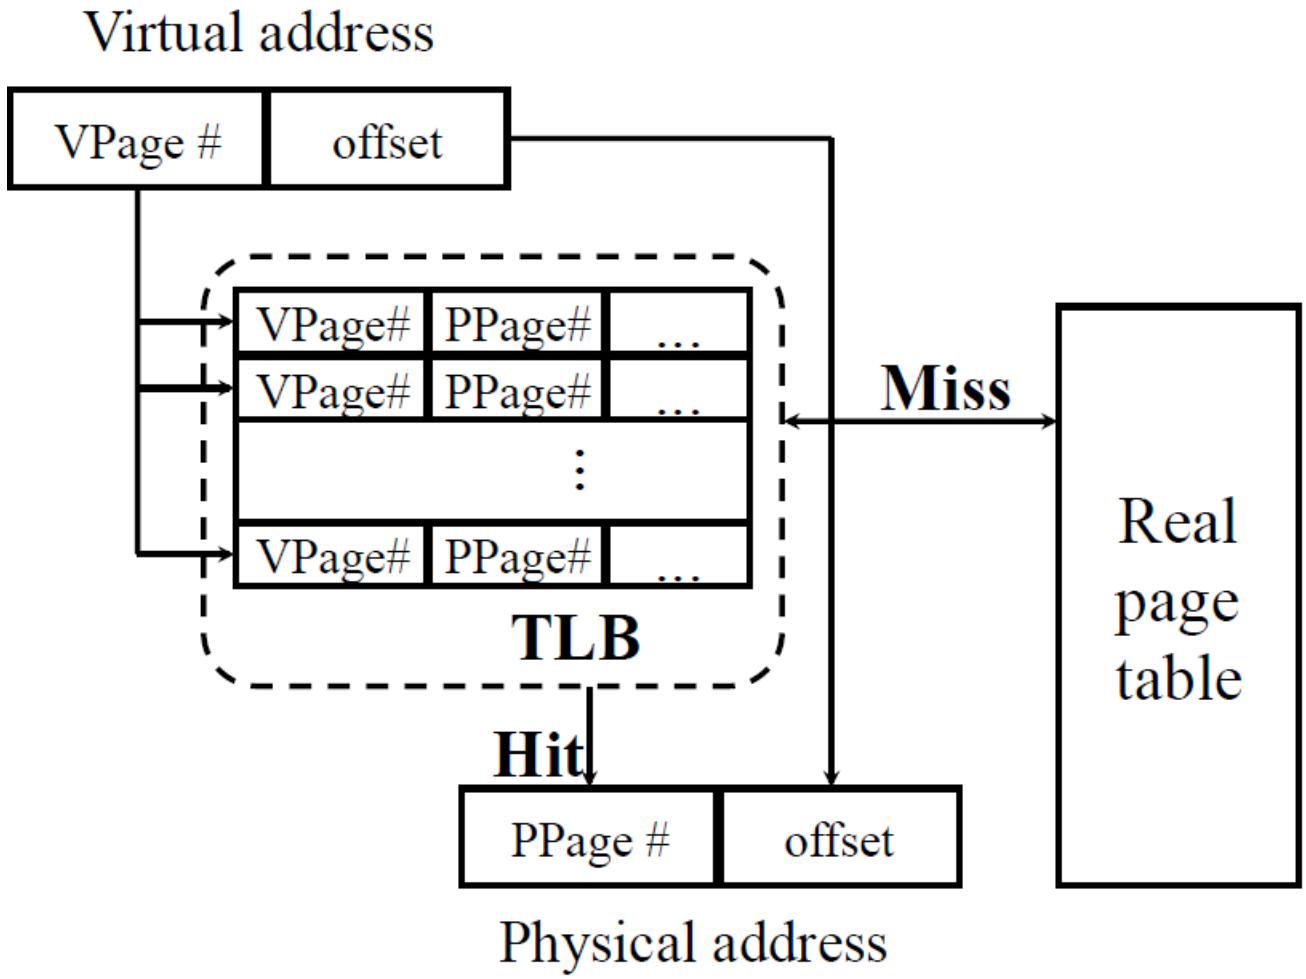

TLB表项的格式

- 共有的（必须的）位
  - VP#（虚页号）：与虚地址进行匹配
  - PP#（物理页号）：转换后的实际地址
  - Valid位：标志此表项是否有效
  - 访问控制位：允许内核/用户访问，以及允许何种访问（nil, read, write）
- 可选的（有用的）位
  - 进程标签 （pid）
  - 访问标志位（R位）
  - 修改标志位（M位）
  - 缓存标志位

硬件控制的TLB

- CPU把一个虚地址VA给MMU进行转换
- MMU先查TLB: VA = VP# || offset
  - 将该虚页号同时与TLB中所有表项进行比较，特殊硬件支持
- TLB hit（命中）：TLB里找到含VP#的表项
  - 如果有效（TLB的valid位=1），取表项中的物理页号
  - 如果无效（TLB的valid位=0），则等同于TLB miss
- 如果TLB miss（不命中）：TLB里没有含VP#的表项
  - MMU硬件在页表中进行查找 ，得到PTE
  - 将找到的PTE加载进TLB
    - 如果没有空闲表项时，替换一个TLB表项
  - 并取TLB表项中的物理页号

软件控制TLB

- CPU把一个虚地址VA给MMU进行转换
- MMU先查TLB: VA = VP# || offset
  - 将该虚页号同时与TLB中所有表项进行比较，特殊硬件支持
- TLB hit（命中）：TLB里找到含VP#的表项
  - 如果有效（TLB的valid位=1），取表项中的物理页号
  - 如果无效（TLB的valid位=0），则等同于TLB miss
- 如果TLB 不命中：TLB里没有含VP#的表项
  - 进入内核异常处理程序（软件 ），软件在页表中进行查找，得到PTE
  - 软件将该PTE加载进TLB
    - 如果没有空闲TLB表项，则替换一个TLB表项
  - 重新执行发生TLB不命中的指令

硬件控制 vs. 软件控制

- 硬件控制
  - 高效
  - 不灵活
- 软件控制
  - 简化MMU的逻辑，使得CPU芯片上更多面积用于缓存
  - 软件控制灵活
  - 可以使用反向页表，进行映射，处理大的虚地址空间
    - hash(Pid, VP#) → PP#

TLB设计问题

- 替换哪个TLB表项
  - 随机 或 最近最少使用算法（伪LRU）
- 上下文切换时需要做什么
  - 有进程标签：修改TLB寄存器和进程寄存器的内容
  - 无进程标签：将整个TLB的内容置为无效
- 修改一个页表项时需要做什么
  - 修改内存中的PTE
  - 将对应的TLB表项置为无效（TLB flush）
- TLB大小
  - 很小的TLB（64个表项），很好的TLB命中率
  - 不能太大（不超过256个表项），CPU的面积有限

CPU缓存 vs. TLB

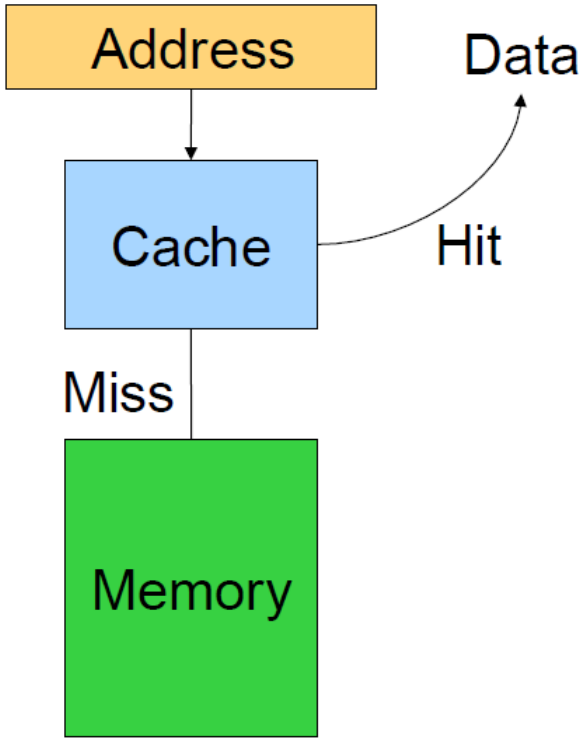

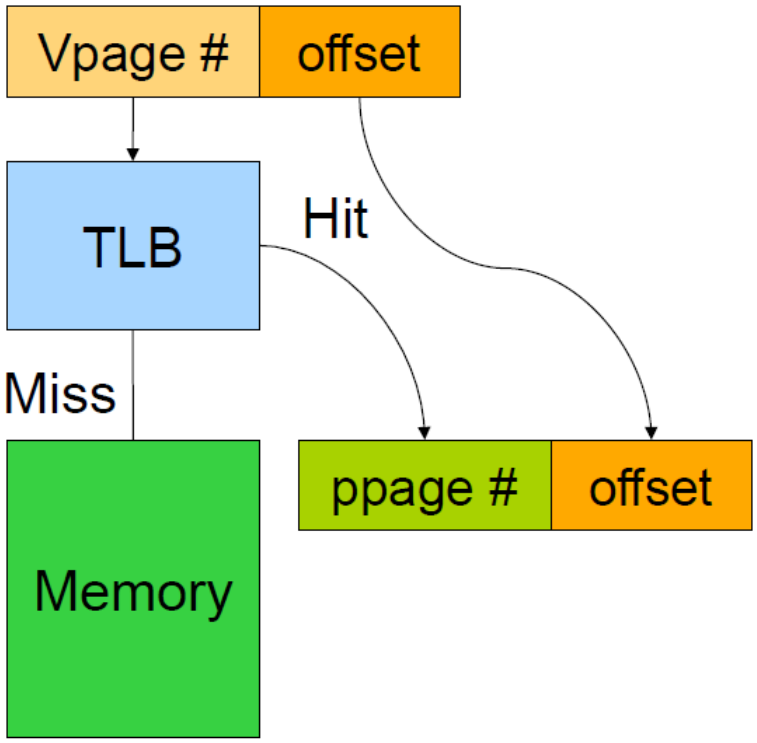

- 相似之处
  - 缓存一部分内存
  - 不命中且满时，进行替换
- 不同之处
  - 关联度：全关联，组关联
  - 一致性：PTE修改

总结

- 虚存
  - 使得软件开发变得容易，而且内存资源利用率更高
- 进程地址空间
  - 分离地址空间能够提供保护和错误隔离
- 地址转换
  - 虚地址与物理地址
  - MMU

总结

- 地址映射
  - 基址+长度：简单，但有很大的局限性
  - 分段：有用，但太复杂
  - 分页
    - 页与页框
    - 页表与PTE
  - 大页表优化：分段+分页、多级页表、反向页表
- TLB
  - 加速地址转换的专门硬件
  - 但引入一致性问题