

# 第七章 参数估计

§1 点估计

§2 估计量的评选标准

# §1 点估计

## 参数估计与非参数估计

- 参数估计——总体分布的类型是已知的，通过样本估计其中的未知参数
- 非参数估计——总体分布的类型是未知的，通过样本估计总体的分布

## 点估计问题

设总体 $X$ 的分布函数 $F(x, \theta)$ 的形式已知(例如：正态分布)， $\theta$ 是待估计参数(例如：期望 $\mu$ )。

$X_1, X_2, \dots, X_n$ 是 $X$ 的一个样本， $x_1, x_2, \dots, x_n$ 是相应的样本值。

构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ ，用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 来估计未知参数 $\theta$ ，称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 $\theta$ 的估计量， $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 $\theta$ 的估计值

这种对未知参数进行定值估计的问题就是点估计问题

概念区分：

- 估计量与估计值
  - **估计量是统计量**，因而是随机变量
  - **估计值**则是一个**标量或向量**
- 在不会导致混淆的情况下，统称估计量与估计值为未知变量 $\theta$ 的估计
- 由于估计量是样本的函数, 是随机变量, 故对不同的样本值, 得到的参数值往往不同, 如何构造和求解估计量是关键问题

常用构造估计量的方法

- 矩估计法
- 最大似然估计法
- 贝叶斯估计

# 矩估计法

若 $X$ 为连续型随机变量，其概率密度函数为

$$f(x; \theta_1, \theta_2, \dots, \theta_k)$$

若 $X$ 为离散型随机变量，其分布律为

$$P\{X = x\} = p(x; \theta_1, \theta_2, \dots, \theta_k)$$

其中， $\theta_1, \theta_2, \dots, \theta_k$ 是待估计参数， $X_1, X_2, \dots, X_n$ 为来自 $X$ 的样本。

设相应的 $l$ 阶矩 $E[X^l] = \mu_l$ 存在， $l = 1, 2, \dots, k$

则 $\mu_l = \mu_l(\theta_1, \theta_2, \dots, \theta_k)$ ， $l = 1, 2, \dots, k$

从样本获得的相应的 $l$ 阶矩为

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l, \quad l = 1, 2, \dots, k$$

于是有包含 $\theta_1, \theta_2, \dots, \theta_k$ 的联立方程组，

$$\begin{cases} A_1 = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ A_2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ \dots \dots \\ A_n = \mu_n(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$$

从中解出方程组的解，记为 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ ，即

$$\begin{cases} \hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_k) \\ \hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_k) \\ \dots \dots \\ \hat{\theta}_k = \hat{\theta}_k(X_1, X_2, \dots, X_k) \end{cases}$$

用 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 分别作为 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量，这种利用矩求估计量的方法称为矩估计法，这种估计量称为**矩估计量**；相应的观察值称为**矩估计值**

## 矩估计法的理论分析

由于 $X_1, X_2, \dots, X_n$ 相互独立，且与总体 $X$ 同分布，  
于是有 $X_1^l, X_2^l, \dots, X_n^l$ 相互独立，且与总体 $X^l$ 同分布，  
故有

$$E(X_1^l) = E(X_2^l) = \dots = E(X_n^l) = \mu_l, l = 1, 2, \dots, k$$

由辛钦大数定律知

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l \xrightarrow{P} \mu_l, l = 1, 2, \dots, k$$

因此可以假设

$$A_l = \mu_l, l = 1, 2, \dots, k$$

用 $A_l$ 估计 $\mu_l$

**独立同分布**的随机变量序列 $\{X_n\}$ ，且具有数学期望 $E(X_k) = \mu, (k = 1, 2, \dots)$ ，则有

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

矩法求估计量的步骤：

1. 求  $\mu_1 = E[X]$  ( $\mu_2 = E[X^2], \dots$ )
2. 设  $A_1 = \mu_1$  ( $A_2 = \mu_2, \dots$ )
3. 解上面的方程(组), 得  $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_k)$ ,  
( $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_k), \dots$ )



例 1 设某炸药厂一天中发生着火现象的次数 $X$ 服从参数为 $\lambda$ 的泊松分布， $\lambda$ 未知，有以下样本：

着火的次数 $k$	0	1	2	3	4	5	6	
发生 $k$ 次着火天数 $n_k$	75	90	54	22	6	2	1	$\sum = 250$

试用矩估计估计参数 $\lambda$ 。

解：因为泊松分布有： $\mu_1 = E[X] = \lambda$

样本的一阶矩为：

$$A_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

$$\text{则 } \hat{\lambda} = \bar{X} = \frac{1}{250} (0 \times 75 + 1 \times 90 + \cdots + 6 \times 1) = 1.22$$

于是 $\lambda$ 的估计值 $\hat{\lambda} = 1.22$

例2. 设总体 $X \sim U[a, b]$ ,  $a, b$ 未知,  $X_1, X_2, \dots, X_n$ 是一个样本, 求 $a, b$ 的矩估计量。

解:  $\mu_1 = E[X] = \frac{a+b}{2}$

$$\mu_2 = E[X^2] = D[X] + (E[X])^2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4}$$

可以令, 
$$\begin{cases} A_1 = \frac{a+b}{2} \\ A_2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4} \end{cases}$$

导出: 
$$\begin{cases} a+b = 2A_1 \\ b-a = \sqrt{12(A_2 - A_1^2)} \end{cases}$$

解得

$$\begin{cases} \hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \\ \hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \end{cases}$$

注意对样本方差的有偏估计

$$A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

例3. 设总体 $X$ 的均值 $\mu$ 、方差 $\sigma^2$ 均存在, 且 $\sigma^2 > 0$ , 但 $\mu$ 、 $\sigma^2$ 未知, 有 $X_1, X_2, \dots, X_n$ 是一个样本。求 $\mu$ 、 $\sigma^2$ 的矩估计量。

解:  $\mu_1 = E[X] = \mu$

$$\mu_2 = E[X^2] = D[X] + (E[X])^2 = \sigma^2 + \mu^2$$

令,  $\mu_1 = A_1, \mu_2 = A_2$

即有 
$$\begin{cases} \mu = A_1 \\ \sigma^2 + \mu^2 = A_2 \end{cases}$$

于是解得

$$\begin{cases} \hat{\mu} = A_1 = \bar{X} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \end{cases}$$

例4. 设总体 $X$ 服从参数为 $\lambda$ 的指数分布, 其中 $\lambda > 0$ 未知,  $X_1, X_2, \dots, X_n$ 是一个样本, 试求参数 $\lambda$ 的矩估计。

解: 总体 $X$ 的密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

于是

$$E[X] = \int_{-\infty}^{+\infty} x f(x) dx = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

令 $\bar{X} = 1/\lambda$

于是得到 $\lambda$ 的矩估计量为

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

例5. 设总体 $X$ 的密度函数为

$$f(x) = \begin{cases} (\alpha + 1)x^\alpha, & 0 < x < 1 \\ 0, & otherwise \end{cases}$$

其中 $\alpha > 0$ 为未知参数，试求参数 $\alpha$ 的矩估计量。

解：

$$E[X] = \int_0^1 x(\alpha + 1)x^\alpha dx = \frac{\alpha + 1}{\alpha + 2}$$

于是令，

$$\bar{X} = \frac{\alpha + 1}{\alpha + 2}$$

由此解得 $\alpha$ 的矩估计量为：

$$\hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}$$

# 极大似然估计(MLE)

## 问题引出

实例1 已知某盒中装有一些黑球和白球，不知道哪种球多，但知道它们的数目比是1:2. 从中有放回地抽取5个球，发现黑球有2只，白球3只. 问盒中哪个球多？

设 $X$ 表示抽取的5个球中黑球的数目，则 $X \sim B(5, p)$

由于数目比为1:2，因此 $p = 1/3$ 或 $p = 2/3$ 。

若 $p = 1/3$ ，则 $P(X = 2) = C_5^2 \left(\frac{1}{3}\right)^2 \left(\frac{2}{3}\right)^3 = \frac{80}{243}$

若 $p = 2/3$ ，则 $P(X = 2) = C_5^2 \left(\frac{2}{3}\right)^2 \left(\frac{1}{3}\right)^3 = \frac{40}{243}$

据此，认为 $p = 1/3$ ，则黑球数目少。

# 极大似然估计

基本假设：

设某一随机试验共有 $A_1, A_2, \dots, A_k, \dots$ 若干可能结果，  
若在一次试验中 $A_m$ 出现，则认为 $A_m$ 出现概率最大。



# 离散型分布的极大似然估计

若总体 $X$ 属离散型，其分布律

$$P\{X = x\} = p(x; \theta), \theta \in \Theta$$

的形式已知， $\theta$ 为待估计参数， $\Theta$ 是 $\theta$ 的取值范围。

设 $X_1, X_2, \dots, X_n$ 是来自 $X$ 的一个样本，则 $X_1, X_2, \dots, X_n$ 的联合分布率为

$$\prod_{i=1}^n p(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是 $X_1, X_2, \dots, X_n$ 的一个样本值，事件 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 发生的概率为：

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

$L(\theta)$ 称为样本的似然函数

# 连续型分布的极大似然估计


若总体 $X$ 属连续型，其概率密度 $f(x; \theta), \theta \in \Theta$ 的形式已知， $\theta$ 为待估计参数， $\Theta$ 是 $\theta$ 的取值范围。

设 $X_1, X_2, \dots, X_n$ 是来自 $X$ 的一个样本，则 $X_1, X_2, \dots, X_n$ 的联合概率密度为

$$\prod_{i=1}^n f(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是 $X_1, X_2, \dots, X_n$ 的一个样本值，则随机点 $(X_1, X_2, \dots, X_n)$ 落在 $(x_1, x_2, \dots, x_n)$ 的邻域( $dx_i$ 为边长的 $n$ 维立方体)内的概率近似为：

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$



## 连续型分布的极大似然估计

选取得到观察值 $(x_1, x_2, \dots, x_n)$ 最大化上式情况下的 $\theta$ 作为其估计值 $\hat{\theta}$

注意到,  $\prod_{i=1}^n dx_i$ 不随 $\theta$ 改变, 故只需考虑

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

$L(\theta)$ 同样称为样本的似然函数

## 极大似然估计原理：

固定 $x_1, x_2, \dots, x_n$ ，选择使概率 $L(x_1, x_2, \dots, x_n; \theta)$ 达到最大的参数 $\hat{\theta}$ 作为对 $\theta$ 的估计值，即取 $\hat{\theta}$ 使得：

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

$\hat{\theta}$ 与 $x_1, x_2, \dots, x_n$ 有关，记为 $\hat{\theta}(x_1, x_2, \dots, x_n)$ ，称其为参数 $\theta$ 的极大似然估计值。

这种求未知参数 $\theta$ 的方法称为极大似然法

若  $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$

则称  $\hat{\theta}(x_1, x_2, \dots, x_n)$  为  $\theta$  的极大似然估计值

称  $\hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  的极大似然估计量

一般情况下  $p(x_i; \theta)$ ,  $f(x_i; \theta)$  关于  $\theta$  可导, 故  $\theta$  可由下式求得:

$$\frac{dL(\theta)}{d\theta} = 0 \quad - \text{似然方程}$$

又因为  $L(\theta)$  与  $\ln L(\theta)$  在同一  $\theta$  处取得极值, 因此有等价的对数似然方程

$$\frac{d}{d\theta} \ln L(\theta) = 0$$

# 样本 $X_1, X_2, \dots, X_n$ 的联合密度函数与似然函数的异同

相同点——形式上一致，都是

$$\prod_{i=1}^n f(x_i; \theta)$$

不同点——

在联合密度函数中 $\theta$  看作是固定数

在似然函数中将 $\theta$ 看作是变量

## 从单一参数到多参数

若总体的分布中包含多个参数，则可令

$$\frac{dL}{d\theta_i} = 0, \quad i = 1, 2, \dots, k$$

或

$$\frac{d\ln L}{d\theta_i} = 0, \quad i = 1, 2, \dots, k$$

解k个方程组求得 $\theta_1, \theta_2, \dots, \theta_k$ 的极大似然估计值

一般而言，极大似然估计优于矩估计

注意：若似然方程（组）无解，或似然函数不可导，此法失效，改用其它方法

例6. 设 $X \sim B(1, p)$ ,  $X_1, X_2, \dots, X_n$ 来自 $X$ 的一个样本, 试求参数 $p$ 的MLE。

解：设 $x_1, x_2, \dots, x_n$ 是一个样本值,  $X$ 的分布律为：

$$P\{X = x\} = p^x(1 - p)^{1-x}, x = 0, 1$$

故似然函数为：

$$\begin{aligned} L(p) &= \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i} \end{aligned}$$

而

$$\ln L(p) = \ln p \sum_{i=1}^n x_i + \ln(1 - p) \left( n - \sum_{i=1}^n x_i \right)$$



令

$$\frac{d\ln L(p)}{dp} = 0$$

得到

$$\frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$$

解得 $p$ 的MLE值为

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$p$ 的MLE量为

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

注意：与矩估计量是相同的

例7. 设总体 $X \sim N(\mu, \sigma^2)$ ，但 $\mu$ 、 $\sigma^2$ 未知， $x_1, x_2, \dots, x_n$ 是一个样本。求 $\mu$ 、 $\sigma^2$ 的极大似然估计量

解：X的概率密度为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

于是似然函数为：

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}} \\ \ln L(\mu, \sigma^2) &= -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

$$\text{令} \begin{cases} \frac{d}{d\mu} \ln L(\mu, \sigma^2) = 0 \\ \frac{d}{d\sigma^2} \ln L(\mu, \sigma^2) = 0 \end{cases},$$

$$\text{得} \begin{cases} \frac{\sum_{i=1}^n x_i - n\mu}{\sigma^2} = 0 \\ -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0 \end{cases}$$

$$\text{解得} \begin{cases} \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases},$$

$$\text{相应的极大似然估计量为} \begin{cases} \mu = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ \sigma^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \end{cases}$$

$$\ln L = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

与相应的矩估计量是相同的

例8. 设总体 $X$ 服从参数为 $\lambda(>0)$ 的泊松分布， $X_1, X_2, \dots, X_n$ 是来自 $X$ 的一个样本，试求参数 $\lambda$ 的最大似然估计量。

解： $X$ 的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad (x = 0, 1, \dots, n)$$

于是 $\lambda$ 的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left( \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$

$$\ln L(\lambda) = -n\lambda + \ln \lambda \sum_{i=1}^n x_i - \sum_{i=1}^n \ln x_i$$

令

$$\frac{d}{d\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0$$

解得 $\lambda$ 的MLE值为

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$\lambda$ 的最大似然估计量为

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

与相应的矩估计量是相同的

例9. 设总体X的密度函数为

$$f(x) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & otherwise \end{cases}$$

其中 $\theta$ 未知,  $\theta > 1$ ,  $X_1, X_2, \dots, X_n$ 是来自X的一个样本, 试求参数 $\theta$ 的最大似然估计

解: 似然函数为:  $L(\theta) = \theta^n (\prod_{i=1}^n x_i)^{\theta-1}$

于是,  $\ln L(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$

令  $\frac{d}{d\theta} \ln L = 0$ , 有似然方程  $\frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0$

解得  $\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln x_i}$ ,

因此 $\theta$ 的极大似然估计量为  $\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln X_i}$

例10. 设总体 $X \sim U[a, b]$ ,  $a, b$ 未知,  $X_1, X_2, \dots, X_n$ 是一个样本, 求 $a, b$ 的极大似然估计量。

注意:  $X$ 的概率密度为 $f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{otherwise} \end{cases}$

似然函数为

$$L(a, b) = \frac{1}{(b-a)^n}$$

$$\ln L(a, b) = -n \ln(b-a)$$

$$\text{于是} \frac{\partial \ln L}{\partial a} = \frac{n}{b-a} = 0, \frac{\partial \ln L}{\partial b} = -\frac{n}{b-a} = 0,$$

显然, 似然方程组无解, 但这不能说明不存在极大似然估计量, 只是不能由似然方程组求解。

解：将 $x_1, x_2, \dots, x_n$ 排序 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$   
则

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)} \leq \dots \leq x_{(n)} \leq b \\ 0, & \text{otherwise} \end{cases}$$

对于满足 $a \leq x_{(1)} \leq \dots \leq x_{(n)} \leq b$ 的任意 $a, b$ 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

即 $L(a, b)$ 在 $b = x_{(n)}, a = x_{(1)}$ 时，取最大值

MLE值为： $\hat{b} = x_{(n)} = \max x_i, \hat{a} = x_{(1)} = \min x_i$

MLE量为： $\hat{b} = \max X_i, \hat{a} = \min X_i$



例11 为了估计湖中有多少条鱼，从湖中捞出1000条鱼，标上记号后又放回湖中，过一段时间后，再捞出150条鱼，发现其中有10条鱼带有标记，估计湖中鱼的总数为多少时使上述事件的概率为最大？

解：设湖中鱼的总数为 $N$ ，则带记号的鱼所占比例为 $1000/N$ ．令 $X$ 为从湖中捞起一条鱼所带有的记号数．则

$$X \sim B(1, p)$$
$$P\{X = x\} = \begin{cases} \frac{1000}{N}, & x = 1 \\ 1 - \frac{1000}{N}, & x = 0 \end{cases}$$

设  $X_i = \begin{cases} 1, & \text{第 } i \text{ 条鱼有标记} \\ 0, & \text{否则} \end{cases}, i = 1, 2, \dots, 150$

由于湖中鱼的数量众多，第二次捞鱼可近似为有放回抽样

于是令

$$Y = \sum_{i=1}^{150} X_i$$

则  $Y = \sum_{i=1}^{150} X_i \sim B\left(150, \frac{1000}{N}\right)$ ，则题中的事件为  $\{Y = 10\}$ ，取似然函数为：

$$L(N) = P\{Y = 10\} = C_{150}^{10} \left(\frac{1000}{N}\right)^{10} \left(\frac{N - 1000}{N}\right)^{140}$$

$$L(N) = C_{150}^{10} \frac{1000^{10} (N - 1000)^{140}}{N^{150}}$$

于是，

$$\ln L(N) = \ln C_{150}^{10} + 10 \ln 1000 + 140 \ln(N - 1000) - 150 \ln N$$

令，

$$\frac{d}{dN} \ln L(N) = \frac{140}{N - 1000} - \frac{150}{N} = 0$$

解得  $N = 15000$

即当湖中的鱼数为15000条时，概率  $P\{Y = 10\}$  为最大。

## 极大似然估计量的不变性

设 $\theta$ 的函数 $u = u(\theta)$ ,  $\theta \in \Theta$ 具有单值反函数,  $\hat{\theta}$ 是 $\theta$ 的极大似然估计, 则

$\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的极大似然估计。

例： $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\sigma^2$ 的极大似然估计，

$u = u(\sigma^2) = \sqrt{\sigma^2}$ 有单值反函数 $\sigma^2 = u^2, (u \geq 0)$

故 $\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$ 是 $\sigma$ 的极大似然估计

例12. 设 $X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma^2$ 未知, 求使 $P\{X > A\} = 0.05$ 的点A的极大似然估计量。

解：

$$P\{X > A\} = 1 - \Phi\left(\frac{A - \mu}{\sigma}\right) = 0.05$$

查表有 $\frac{A - \mu}{\sigma} = 1.645$ , 故有 $A = \mu + 1.645\sigma$

由前面知 $\mu, \sigma^2$ 的极大似然估计量分别为：

$$\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

故A的极大似然估计量为

$$\hat{A} = \hat{\mu} + 1.645\hat{\sigma} = \bar{X} + 1.645 \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

## §2 估计量的评选标准

**缘起：**对于同一个参数, 用不同的估计方法求出的估计量可能不相同。而且, 很明显, 原则上任何统计量都可以作为未知参数的估计量

### 问题

- (1) 对于同一个参数究竟采用哪一个估计量好?
- (2) 评价估计量的标准是什么?

### 考虑估计的性质

- (1) 无偏性
- (2) 有效性
- (3) 相合性(一致性)

## 一、无偏性

若 $X_1, X_2, \dots, X_n$ 为总体 $X$ 的一个样本， $\theta \in \Theta$ 是包含在总体 $X$ 的分布中的待估计参数，

若估计量 $\hat{\theta} = \theta(X_1, X_2, \dots, X_n)$ 的数学期望 $E(\hat{\theta})$ 存在且对于任意 $\theta \in \Theta$ 有 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 为 $\theta$ 的无偏估计量

无偏估计意味着无系统性误差

例13. 设总体 $X$ 的 $k$ 阶矩 $\mu_k = E(X^k)$  ( $k \geq 1$ )存在, 又设 $X_1, X_2, \dots, X_n$ 为总体 $X$ 的一个样本, 试证明不论总体服从何种分布,  $k$ 阶样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 $k$ 阶总体矩 $\mu_k$ 的无偏估计。

证明: 因为 $X_1, X_2, \dots, X_n$ 与 $X$ 同分布, 故有

$$E(X_i^k) = E(X^k) = \mu_k$$

即

$$E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k$$

故 $k$ 阶样本矩 $A_k$ 是 $k$ 阶总体矩 $\mu_k$ 的无偏估计

**注意:** 不论总体  $X$  服从什么分布, 只要它的数学期望存在,  $\bar{X}$ 总是总体 $X$ 的数学期望 $\mu_1 = E(X)$ 的无偏估计



例14. 对于均值 $\mu$ ，方差 $\sigma^2$ 都存在的总体，若 $\mu$ 和 $\sigma^2$ 均为未知，则 $\sigma^2$ 的估计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是有偏的。

$$\text{证明： } \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = A_2 - \bar{X}^2$$

$$\text{因为 } E(A_2) = \mu_2 = \sigma^2 + \mu^2$$

$$\text{而 } E(\bar{X}^2) = D(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2$$

于是有

$$\begin{aligned} E(\hat{\sigma}^2) &= E(A_2 - \bar{X}^2) = E(A_2) - E(\bar{X}^2) \\ &= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2 = \frac{n-1}{n} \sigma^2 \neq \sigma^2 \end{aligned}$$

故是有偏的。

若以 $\frac{n}{n-1}$ 乘以 $\hat{\sigma}^2$ ，所得到的估计量就是无偏的(这种方法称为无偏化)

$$E\left(\frac{n}{n-1}\hat{\sigma}^2\right) = \frac{n}{n-1}E(\hat{\sigma}^2) = \sigma^2$$

因为

$$\frac{n}{n-1}\hat{\sigma}^2 = S^2 = \frac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X})^2$$

即 $S^2$ 是 $\sigma^2$ 的无偏估计，通常取 $S^2$ 作为 $\sigma^2$ 的估计量

例16. 设 $X \sim N(\mu, \sigma^2)$ ,  $\mu$ 已知,  $\sigma^2$ 未知,  $x_1, x_2, \dots, x_n$ 是来自 $X$ 的一个样本值, 求 $\sigma^2$ 的极大似然估计量。

解:  $X$ 的概率密度函数为:

$$f(x; \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

似然函数为:

$$\begin{aligned} L(\sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right\} \\ \ln L &= -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

令

$$\frac{d}{d\sigma^2} \ln L = -\frac{n}{2\sigma^2} - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0$$

解得：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

注意到

$$\begin{aligned} E(\hat{\sigma}^2) &= E\left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2\right) \\ &= \frac{1}{n} \sum_{i=1}^n E[(x_i - \mu)^2] = \frac{1}{n} \times n\sigma^2 = \sigma^2 \end{aligned}$$

故， $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$  是总体的无偏估计

例17. 设总体 $X$ 服从参数为 $\theta$ 的指数分布，概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & otherwise \end{cases}$$

参数 $\theta > 0$ ，又设 $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 的样本，试证 $\bar{X}$ 和 $nZ = n[\min(X_1, X_2, \dots, X_n)]$ 都是 $\theta$ 的无偏估计。

证明：因为 $E(\bar{X}) = E(X) = \theta$ ，  
所以 $\bar{X}$ 是 $\theta$ 的无偏估计量。

而  $Z = \min(X_1, X_2, \dots, X_n)$  服从参数为  $\frac{\theta}{n}$  的指数分布，

$$f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0 \\ 0, & \text{otherwise} \end{cases}$$

故知  $E(Z) = \frac{\theta}{n}$ ,  $E(nZ) = \theta$ ,

所以  $nZ$  也是  $\theta$  的无偏估计量。

由此可知，一个参数可以有不同的无偏估计量

注意：如果未知参数  $\theta$  有两个不同的无偏估计量  $\hat{\theta}_1$  和  $\hat{\theta}_2$ ，则一定有无穷多个无偏估计

$$\alpha \hat{\theta}_1 + (1 - \alpha) \hat{\theta}_2$$

## 二、有效性

比较参数 $\theta$ 的两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ ，如果在样本容量 $n$ 相同的情况下， $\hat{\theta}_1$ 的观察值在真值 $\theta$ 的附近较 $\hat{\theta}_2$ 更为密集，则认为 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效

由于方差是随机变量取值与其数学期望的偏离程度，所以无偏估计以方差小者为好

形式化：

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 $\theta$ 的无偏估计量，若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ ，则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效

例18. 设总体 $X$ 服从参数为 $\theta$ 的指数分布，概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{otherwise} \end{cases}$$

参数 $\theta > 0$ ，又设 $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 的样本，试证 $\theta$ 的无偏估计中，当 $n > 1$ 时 $\bar{X}$ 较 $nZ$ 更为有效。

证明：由于 $D(X) = \theta^2$ ，故有 $D(\bar{X}) = \frac{\theta^2}{n}$

又因为 $D(Z) = \frac{\theta^2}{n^2}$ ，故有 $D(nZ) = \theta^2$

当 $n > 1$ 时， $D(nZ) > D(\bar{X})$ ，

所以 $\theta$ 的无偏估计中，当 $n > 1$ 时 $\bar{X}$ 较 $nZ$ 更为有效



### 三、相合性(一致性)

若  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  为参数  $\theta$  的估计量, 如果对于任意  $\theta \in \Theta$ , 当  $n \rightarrow \infty$  时  $\hat{\theta}_n \xrightarrow{P} \theta$ , 则称  $\hat{\theta}$  是  $\theta$  的一致估计。

例19. 若  $X_1, X_2, \dots, X_n$  是总体  $X$  的样本,  $E[X] = \mu$ ,  $E[X^k] = \mu_k$ , 有辛钦大数定理, 知对任意给定的  $\epsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| \geq \epsilon \right\} = 0$$

因此, 样本均值  $\bar{X}$  是总体期望  $\mu$  的相合(一致)估计量

# 作业

概率论与数理统计

pp. 173-175, #2 , #5 , #10 , #12